



Centro Federal de Educação Tecnológica de Minas

Gerias

Departamento de Engenharia Elétrica

Engenharia Elétrica

PREVISÃO DE CURTO PRAZO DO CONSUMO ENERGÉTICO DE PRÉDIOS PÚBLICOS EM MINAS GERIAS

Evandro Ribeiro Gomes Coelho

25/02/2021

Centro Federal de Educação Tecnológica de Minas Gerais
Departamento de Engenharia Elétrica
Av. Amazonas, 7675 - Nova Gameleira, Belo Horizonte - MG, 30510-000
(33) 99151-9276 – evandrorcoelho@gmail.com

Evandro Ribeiro Gomes Coelho

PREVISÃO DE CURTO PRAZO DO CONSUMO ENERGÉTICO DE PRÉDIOS PÚBLICOS EM MINAS GERAIS

Trabalho de Conclusão de Curso submetida
à banca examinadora designada pelo
Colegiado do Departamento de Engenharia
Elétrica do Centro Federal de Educação
Tecnológica de Minas Gerais, como parte
dos requisitos necessários à obtenção do
grau de Bacharel em Engenharia Elétrica.

Área de Concentração: Engenharia Elétrica
Orientador(a): Cássia Regina Santos Nunes
Almeida
Centro Federal de Educação Tecnológica de
Minas Gerais

Belo Horizonte
Centro Federal de Educação Tecnológica de Minas Gerais
2021

Folha de Aprovação a ser anexada

Aos meus pais, Aluísio e Fabiane.

Agradecimentos

Agradeço à Deus pela graça de completar mais um ciclo e por todo conhecimento adquirido nessa formação.

Agradeço aos meus pais, Aluísio e Fabiane, que estiveram sempre presentes nessa jornada e me apoiaram em todos os dias, principalmente os mais difíceis, em que uma simples ligação diminui a distância física de estudar em outra cidade. Agradeço também a minha irmã, Amanda, que foi motivação pra ser exemplo e seguir em frente.

Aos meus tios, Eberaldo e Márcia, por me acolherem como um filho e concederem a oportunidade de estudar em uma excelente faculdade. Aos meus primos, Nilo, Emerson e Marina pela companhia e apoio durante esses anos.

À minha tia Vânia, que foi incentivo e peça fundamental para estudar inglês quando criança.

Aos amigos que fiz no CEFET, pelo apoio em cada disciplina e por tornarem mais leve os dias de estudos. Em especial, agradeço à minha companheira, amiga e namorada, Natália, que me ajudou a equilibrar os estudos com o trabalho e descanso. Obrigado pela parceria e apoio na carreira profissional.

Ao Breno, pelo aprendizado durante o período de estágio e esforços para autorizar o uso dos dados do Tribunal Regional do Trabalho para esse estudo.

Ao professor Rodrigo, que no início do curso, foi incentivo para trabalhar com programação e ciência de dados.

À professora e orientadora Cássia, que além dos ensinamentos em sala de aula, foi responsável por guiar os alunos nas escolhas profissionais e pessoais.

Por fim, agradeço também ao CEFET, que proporcionou um ensino de qualidade e de reconhecimento no mercado.

Resumo

No âmbito do consumo energético em prédios públicos existe a necessidade do registro estruturado dos gastos de energia para controle interno, o que possibilita o estudo dos gastos considerando os dados históricos. Uma das abordagens que fazem a aplicação dessas informações é a previsão do consumo. A previsão de curto prazo, que considera aspectos históricos de comportamento das unidades consumidoras, auxilia na gestão das faturas e no devido ateste do serviço prestado, que fica sobre responsabilidade do fiscal do contrato público. Verifica-se que a maior parte dos gastos de energia estão relacionados com sistemas de iluminação e climatização. Assim, a previsão também é utilizada como sinalizador de problemas elétricos e incentiva as manutenções preventivas. Essa pesquisa se propõe realizar um estudo de previsão de dados de energia no setor público, além de realizar uma revisão bibliográfica da área. Por fim, o trabalho foi desenhado para apresentar a estruturação da base de dados e as características para implementação. Estudou-se inicialmente um conjunto de dados públicos que se refere aos gastos de energia do Tribunal Regional do Trabalho 3ª Região.

Palavras-chave: Previsão de consumo energético de curto prazo. Gestão de faturas de energia. Prédios públicos.

Abstract

Within the scope of energy consumption in public buildings, there is a need of structured registration of energy bills for intern controls, which allows researches about expenditures considering historical data. One of the approaches is the energy forecast. The short-term forecast, that consider historical behavior aspects of the consumer units, assists in the bill management and attest the rendered service, which stays on the responsibilities of the public contract inspector. It is verified that most of the energy spent is related to illumination and climatization systems. Thus, the forecast is also used as a flag to electrical problems and it encourages the preventive maintenance. This research aims to accomplish a study about energy forecast in the public sector, beyond to perform a bibliographic review of the area. Lastly, this research scope was designed to present the data set and the characteristics of its implementation. It was chosen to study the public data set of energy consumption of the Tribunal Regional do Trabalho 3ª Região.

Keywords: Short term energy consumption forecast. Energy bill management. Public building.

Sumário

Resumo.....	i
Abstract.....	ii
Sumário	iii
Lista de Figuras	iv
Lista de Tabelas.....	v
Lista de Abreviações.....	vi
Capítulo 1	7
Capítulo 2	10
2.1. Consumo Energético.....	10
2.2. Gestão de faturas.....	12
2.3. Previsão de dados	15
2.3.1. Séries temporais para modelagem de energia	17
2.3.2. Métodos de previsão de curto prazo.....	19
2.4. Validação Cruzada	29
2.4.1. Sobreajuste.....	32
2.4.2. Subajuste	33
2.4.3. Regularização	33
2.4.4. Hyperparameters.....	35
Capítulo 3	36
3.1. Base de dados	36
3.1.1. Edifícios de interesse	37
3.2. Análises iniciais.....	38
3.3. Implementação	39
Capítulo 4	41
Referências Bibliográficas	43

Lista de Figuras

Figura 2-1 - Esquema interno de um neurônio (Fonte: O autor)	21 20
Figura 2-2 - Ilustração genérica de um modelo <i>shallow learning</i> . (Hyndman & Athanasopoulos, 2018) 23 22	
Figura 2-3 - Validação do modelo de treino sobre o modelo de teste. (Google Inc., 2020)	30 29
Figura 2-4 - Visualização dos grupos de dados de forma genérica. (Shah, 2020).....	30 29
Figura 2-5 - Ajuste polinomial de diferentes ordens para uma função senoide (Towards Data Science, 2018)	34 33
Figura 3-1 - Esquema da Base de Dados Relacional.....	37 36

Lista de Tabelas

Tabela 3-1 - Edifícios de interesse Tribunal Regional do Trabalho 3ª Região	38
---	----

Lista de Abreviações

ANEEL	Agência Nacional de Energia Elétrica
ANN	Artificial Neural Network
ARIMA	Auto Regressive Integrated Moving Average
DA HFP	Demanda Ativa em Horário Fora de Ponta
DA HP	Demanda Ativa em Horário de Ponta
EA HFP	Energia Ativa em Horário Fora de Ponta
EA HP	Energia Ativa em Horário de Ponta
INEE	Instituto Nacional de Eficiência Energética
MME	Média Móvel Exponencial
MMS	Média Móvel Simples
PROCEL	Programa Nacional de Conservação de Energia Elétrica
RE HFP	Energia Reativa em Horário Fora de Ponta
RE HP	Energia Reativa em Horário de Ponta
RL	Regressão Linear
RP	Repressão Polinomial
SVM	Support Vector Machine
TRT3	Tribunal Regional do Trabalho 3ª Região

Capítulo 1

Introdução

Desde a crise do petróleo, que aumentou o preço do barril na década de 70, os países começaram a colocar o fornecimento de energia como prioridade. O Brasil estabeleceu diversas medidas para garantir o suprimento de energia dentro do território nacional e minimizar as dependências das commodities, como é o caso do Programa Nacional de Conservação de Energia Elétrica (PROCEL), criado em 1985.

Em relação ao suprimento e consumo de energia elétrica, o conceito de eficiência energética visa o desenvolvimento de projetos considerando as perdas de equipamentos. Ademais, existe também a demanda de otimizar os gastos de energia obtendo sinais internos de consumos ineficientes. Exemplos de ineficiência ocorrem com iluminações em ambientes sem utilização, sistemas de climatização desregulados, correntes de fuga em instalações antigas etc.

Como consequência direta do consumo ineficiente de energia há o maior gasto financeiro, seja por perdas em equipamentos ou desperdício. Segundo d'Albuquerque, Silva, & Gomes (2017), existem casos em que edificações públicas ainda mantêm equipamentos de alto consumo energético. Citando o autor:

“Quanto ao sistema de climatização, na maioria dos ambientes são utilizados aparelhos [...] com selo PROCEL de eficiência energética classe A, embora permaneça em uso equipamentos do tipo split com selo PROCEL de eficiência energética classe C ou, ainda, antigos sistemas de climatização de alto consumo energético.”

Quando se pondera o gasto de energia de um edifício como um todo, surgem dúvidas para inferir se o consumo está de acordo com os valores esperados. Ainda citando d'Albuquerque, Silva, & Gomes (2017), analisar uma construção civil como uma grande unidade consumidora se torna um desafio ao avaliar os diversos fatores internos

desses edifícios, como variedade de equipamentos elétricos distribuídos pela área útil e população flutuante.

As construções públicas de atividade laboral contam com outro fator que pode afetar o estudo do consumo de energia. A gestão dos consumos e gastos dos prédios públicos possuem como jurisprudência a Lei nº8.666/1993, que se refere a liquidações de despesas públicas e ficam centralizadas aos fiscais dos contratos. Esse mecanismo, embora siga o ritual de ateste para garantir transparência aos gastos da união, pode gerar um problema de gestão de faturas. A análise apenas dos gastos dos últimos meses carece de informações relevantes para concluir se o consumo mensal do prédio está de acordo com o que se espera.

Nesse sentido, uma das possibilidades para a análise do consumo de energia é coletar o maior intervalo possível de dados de consumo desses edifícios de forma estruturada, a fim de ser possível construir uma série temporal desses valores e buscar ferramentas de modelagem matemática para essas informações. Segundo Wei (2017), “métodos de previsão considerados de alta complexidade (*deep learning*) já foram empregados para descrever o comportamento desses prédios, como algoritmos de Redes Neutrais Artificiais e Máquinas de Vetores de Suporte”. Todavia, há a possibilidade de estudar o comportamento dessa série temporal com algoritmos que não precisam de uma grande quantidade de dados relacionados e que não seja necessário o desenvolvimento de diversas camadas de aprendizado, mas que ainda garantam a confiabilidade do sistema de predição. Como aponta Zhao and Magoulès (2012), os modelos puramente estatísticos possuem menor complexidade de implementação e boa precisão.

Esse trabalho tem como foco encontrar de forma empírica um método de aprendizagem que melhor se adeque ao comportamento da série temporal do consumo de energia de prédios públicos do Tribunal Regional do Trabalho da 3ª Região. É de competência também desse estudo a validação dos algoritmos e parâmetros para verificar o nível de precisão dos mesmos.

A metodologia a ser empregada foi de coleta, tratamento e estruturação dos dados. Em seguida, propõe-se a validação cruzada dos conjuntos de dados para determinar o melhor ajuste do método e garantir que o algoritmo não resulte um resultado sobreajustado. Por fim, sugere-se que o resultado das previsões seja

comparado com o último dado coletado da base de dados, para se obter as métricas de precisão do método.

Espera-se que esse trabalho forneça informações para o processo de pagamento de despesas públicas e que seja de fácil implementação para demais setores laborais, assim garantindo melhor uso dos recursos naturais e menores gastos públicos. Ademais, o desenvolvimento de uma metodologia para auxiliar na gestão das instalações pode gerar sinalizadores de manutenções ou ainda motivem projetos para minimizar desperdícios em prédios administrativos. Isso porque a comparação do valor previsto com o realizado pode servir como parâmetro para ateste e análise do consumo do mês vigente. Por fim, esse estudo abre margem para novas trabalhos associando técnicas de aprendizado de máquinas e eficiência energética, considerando os dados disponibilizados em faturas de energia.

Capítulo 2

Referencial Teórico

O uso da energia está presente de forma intensiva na maior parte das atividades humanas. Dentre as diversas formas de energia, as que são processadas pela sociedade e colocadas à disposição de consumidores abre um grande leque de estudos, seja na forma de gás natural, combustível, eletricidade, etc.

Com o uso extensivo de energia, passou também a se tornar preocupação e objeto de estudo o seu uso eficiente. Nesse sentido, a fim de embasar o estudo de previsão do consumo energético de prédios públicos, torna-se necessário relacionar o consumo de energia desses edifícios com a situação de gestão das despesas e uso eficiente do recurso natural.

2.1. Consumo Energético

A Associação Brasileira das Empresas de Serviço e Conservação de Energia (2020) define eficiência energética como “a utilização racional de energia chamada também simplesmente de eficiência energética, consiste em usar de modo eficiente a energia para se obter um determinado resultado”. Assim, está diretamente associada a eficiência dos dispositivos, que por definição é consiste na relação entre a quantidade de energia empregada em uma atividade e aquela disponibilizada para sua realização.

A eficiência dos dispositivos elétricos não é a única variável que pode gerar maiores gastos energéticos. Além das perdas associadas aos equipamentos, outro fator importante de análise está relacionado com o desperdício de energia. Isso se dá principalmente pelo uso de equipamentos antigos e pouco eficientes, como já foi abordado por d’Albuquerque, Silva, & Gomes (2017).

Segundo o PROCEL (2020), “os projetos de eficiência energética, em geral, atuam em primeiro momento na substituição de equipamentos ineficientes”. Entretanto, esse método está associado ao custo de aquisição de novo material e mão de obra para implementação. Esses podem ser chamados de *retrofits*, termo utilizado para designar o processo de modernização de algum equipamento já considerado ultrapassado ou fora de norma. Um exemplo amplamente utilizado é a troca de lâmpadas fluorescentes para a tecnologia LED, que fornece intensidades luminosas maiores com menor gasto energético.

O PROCEL (2020) ainda complementa que, em relação aos edifícios, “cerca de 70% do consumo de energia se deve ao uso dos sistemas de iluminação e climatização dessas edificações”. Esse dado confirma a importância de averiguar as despesas de energia dos principais agentes consumidores com as necessidades do prédio, a fim de garantir a otimização da construção para necessidades do setor público.

Todavia, existem estratégias alternativas para se garantir maior eficiência no consumo de energia. A principal delas consiste na mudança de hábitos dos indivíduos em um ambiente de trabalho, que pode alterar o comportamento do consumo de energia.

Afrânio Gonçalves (2012), no âmbito das edificações públicas, por se tratar de um ambiente laboral, afirma que os “estudos se concentram em avaliar as migrações de tarifas e se embasam na série histórica das instalações”, ou seja, calcula-se o consumo e a demanda média das edificações públicas para se avaliar a viabilidade de construir uma subestação própria e migrar o grupo tarifário de baixa para média tensão. Entretanto, para análise do histórico de consumo, torna-se imprescindível a devida coleta dos dados de forma estruturada ao longo dos anos.

Segundo d’Albuquerque, Silva, & Gomes (2017), a partir dos dados, é possível “selecionar algumas das principais fontes de consumo e relacionar com, por exemplo, a quantidade de usuários no desempenho de suas funções, a quantidade de dias úteis, a quantidade de visitantes (população flutuante) ou a quantidade de novos equipamentos instalados”.

Por fim, outro fator que pode contribuir para o desperdício de recursos naturais e está ligando diretamente com os recursos financeiros é a devida gestão e análise das faturas. Ainda na obra “Eficiência Energética Em Uma Edificação Pública: Uma Análise

Das Possibilidades,” d’Albuquerque, Silva, & Gomes (2017) motivam a análise da fatura energética:

“A análise dos dados fornece subsídios para o planejamento e execução de ações estratégicas na gestão do consumo de energia elétrica, como a elaboração de política energética interna, a revisão de contratos e sistemas tarifários, a análise de custo-benefício da implantação de tecnologias energeticamente eficientes, o alinhamento de parcerias com universidades para estudos, realização de compras em conjunto com outros órgãos públicos, disponibilização dos indicadores de EE a todos os usuários da instituição e a sensibilização por meio de medidas de educação e de treinamento.”

Assim, a correta administração das despesas pode evitar gastos com inadimplência, que afeta os gastos públicos, além de servir como indicador para problemas na infraestrutura do circuito elétrico.

Isso vai ao encontro com as atividades do fiscal do contrato público e suas responsabilidades. Dessa forma, o presente estudo também possui como fundamentação teórica o consumo energético relacionado à gestão das faturas, que por sua vez envolve a devida verificação do serviço prestado até a liquidação da despesa.

2.2. Gestão de faturas

O consumo de energia elétrica em prédios públicos afeta os gastos da união. A correta análise da série histórica pode indicar alterações relativas ao consumo e, em muitos casos, pode servir como sinalizador de problemas na rede ou importantes alterações de comportamento humano. Segundo a Resolução Normativa nº414 da ANEEL, com relação aos dados do consumo energético, as contas de energia deverão conter dados de leitura de medidor, valor total a pagar e histórico de consumo de cada mês. Assim, os dados disponibilizados pela concessionária podem ser considerados

insuficientes para a análise do faturamento da construção em uma janela de tempo maior.

A análise do histórico pode ser pouco eficiente para instalações individuais de baixa tensão, pois as grandes variações do consumo estão fortemente ancoradas com os hábitos de humanos do período em questão. Nesse sentido, o estudo das variações de pequenas instalações nem sempre está relacionado com um precursor de ineficiência ou problemas no circuito elétrico, como é o caso de instalações domésticas. Todavia, as características de comportamento entre os prédios públicos administrativos são semelhantes, considerando os padrões de uso e o propósito dessas edificações. Ademais, esses prédios contam com diversos circuitos que compõem uma grande unidade consumidora. Assim, adotar medidas de controle e registo da série histórica do consumo de forma estruturada é a primeira etapa de um processo visando melhor gestão das faturas.

É necessário compreender o processo de liquidação de uma fatura de energia. Segundo Antônio França da Costa (2020), Auditor Federal de Controle Externo do Tribunal de Contas da União, “o processo de pagamento de uma despesa pública se inicia na fatura desse serviço”.

Como a administração pública se equipara ao consumidor final de característica jurídica para os gastos de energia elétrica, salvo a isenção fiscal, o documento que comprova o consumo chega ao fiscal do contrato público. Esse servidor, que possui fé pública e devida capacidade técnica para realizar o julgamento, atesta a fatura e reconhece que o serviço foi prestado. Citando Costa (2020):

“É na fase da liquidação da despesa que o fiscal de contrato se mostra em relevo, ao atestar as medições, ao não apontar ressalvas na prestação do serviço em seus registros, ou ao apontá-las e exigir glosas nos pagamentos.”

A próxima etapa é encaminhar para liquidação, para conferir documentações e por fim ocorre o efetivo crédito bancária na conta da concessionária. Costa (2020) ainda complementa que:

“O objetivo da liquidação é certificar se houve o implemento da condição por parte do contratado, se ele cumpriu o que foi pactuado. A liquidação visa verificar a origem e o objeto do que se deve pagar, a importância exata a pagar, e a quem se deve pagar a importância para extinguir a obrigação.”

Sobre as despesas de energia elétrica, pode-se verificar que a composição das notas fiscais em prédios públicos é mista, podendo ser fragmentada em diversos medidores. Analisar individualmente cada circuito elétrico, apesar de mais específica e demandar maior carga laboral, pode apresentar resultados de grande impacto relativo ao consumo.

Apesar dessa fragmentação, as análises de gastos com energia elétrica no âmbito público podem levar em consideração o prédio administrativo como um todo. As variações apresentadas em um medidor podem ser compensadas em outra instalação da mesma construção e não seriam justificadas intervenções ou maiores análises. Ademais, a análise global otimiza o processo de pagamento com uma visão macroscópica do consumo energético.

É comum que um fiscal de contrato seja responsável por mais de um prédio e, por consequência, um grande número de instalações fragmentadas que geram faturas mensais. A partir dessa análise prática, pode-se considerar que uma das estratégias para o controle das despesas dessa prestação de serviço é a análise do prédio como uma instância geral, representada pelo agrupamento de todas as faturas internas.

Além de facilitar as análises substituindo a quantidade de variáveis com pequenas influências para entidades consumidoras gerais, torna-se possível também comparar de forma macroscópica o comportamento de sistemas semelhantes em construção e finalidade.

Portanto, torna-se uma solução mais efetiva a previsão do consumo energético do mês seguinte para uma unidade consumidora composta de várias instalações elétricas. Essa informação otimiza o ritual de ateste e embasa as decisões dos fiscais dos contratos com base em uma metodologia previamente estabelecida. Como foi exposto por d’Albuquerque, Silva, & Gomes (2017), os impasses do uso eficiente de energia está na “falta de profissionais com formação especializada em EE nas instituições públicas e quanto à falta de tempo adequado em sua jornada de trabalho para dedicar-se a gestão

da EE.”. De posse das informações de consumo histórico, o gestor do contrato pode tomar ações para minimizar o desprendimento de capital com multas e juros de atrasos. Ademais, essa metodologia abre espaço para novas considerações e sinaliza grande variações do comportamento humano com o tempo.

2.3. Previsão de dados

O dicionário português define previsão como: “suposições sobre o que ainda não ocorreu; conjectura; O que se faz antecipadamente; antevisão”. A busca por anteceder eventos e comportamento futuros se tornou uma grande área de estudo humano.

Há modelos e métodos científicos para realizar a previsão de determinadas áreas. No âmbito da engenharia elétrica, Amasyali & El-Gohary (2017) motivam o estudo da previsão do consumo de energia:

“[...] it is recognized that realization of a precise energy consumption analysis is a formidable task at the current stage. As an alternative, great efforts have been paid to developing models to predict and classify approximately energy consumption. [...] The results simulated by these models can not only offer essential information about energy footprint in regional building stocks, but also facilitate estimations of financial/environmental return/benefits on investment.”

O uso de energia elétrica em prédios leva em consideração diversos fatores, como condições climática, comportamento humano, ocupação dos edifícios, características do circuito elétrica, propósito de uso da construção, etc. A grande quantidade de variáveis de influência leva a um comportamento distinto e aleatório da curva de consumo. Mesmo assim, torna-se possível identificar alguns padrões na série histórica, visto que algumas variáveis possuem maiores influências no uso de energia, como a população flutuante, abordada por d’Albuquerque, Silva, & Gomes (2017).

Dessa forma, os modelos de previsão de energia são de importância para garantir o uso eficiente dos recursos naturais. De forma geral, existem duas abordagens para a previsão do consumo de energia, sendo elas ou baseadas em modelos físicos ou baseadas em dados históricos. Os modelos físicos descrevem o gasto energético a partir de relações termodinâmicas e outras características físicas. Esses modelos calculam o consumo de prédios considerando parâmetros do ambiente e aspectos construtivos. Ademais, estão diretamente ligados à qualidade dos parâmetros iniciais, sendo que nem sempre os dados climáticos e de construção podem estar disponíveis durante a simulação.

Por outro lado, modelos orientados a dados não requerem dados de construção de edifícios ou das características climáticas vigentes. Eles fazem uma abordagem preditiva considerando os dados históricos disponíveis. Mesmo possuindo suas limitações, o estudo por essa metodologia cresceu e se mostra promissor em abordagens de aprendizagem de máquina ou até mesmo o tratamento por algoritmos vetorizados.

No estudo sobre a abordagem orientada a dados, Zhao and Magoulès (2012), classificam os diversos tipos de previsão de já estudados para o consumo de energia. Os autores definem três categorias para os modelos de previsão:

“Currently, these approaches used for building energy simulation are categorized roughly as: (1) white-box based approaches, (2) grey-box based approaches and (3) black-box based approaches”.

Ainda segundo Zhao and Magoulès (2012), a categoria *White-box* tem como abordagem um modelo físico que necessita de informações sobre os fenômenos que ocorrem ao entorno do edifício. Em geral, esse modelo superestima a economia de uma construção.

Por sua vez, o modelo *Grey-box* é uma modificação do modelo *White-box*. Sua abordagem é a partir de métodos estatísticos combinados com uma versão simplificada dos fenômenos físicos com o histórico de consumo energético. Como característica geral, esse modelo envolve entradas de dados que são incertas com elementos estocásticos.

Por fim, a abordagem *Black-box* para análise do consumo de energia de um prédio se ampara apenas nos dados de consumo histórico, sem influências dos dados

relacionados a fenômenos físicos. Conforme Zhao em Magoulès (2012), essa mudança “torna os modelos *black-box* de alta precisão e de rápido cálculo”.

Dessa forma, considerando que as construções públicas se munem, em sua maior parte, apenas dos dados históricos de consumo ao longo do tempo, torna-se justificável analisar e prever os dados a partir de uma abordagem *black-box*, ou seja, orientada apenas aos dados históricos.

Ademais, esse trabalho também busca definir e justificar a modelagem do histórico de energia como uma série temporal, a fim de viabilizar certos métodos e análises estatísticas.

2.3.1. Séries temporais para modelagem de energia

Segundo Downing & Clark, (2006), “As séries temporais (ou históricas) são conjuntos de medidas de uma mesma grandeza, relativas a vários períodos consecutivos”. A equação 2-1 mostra a definição de um evento específico de uma série temporal.

$$S_t = a + b \cdot x_t + \epsilon_t \quad (2.1)$$

Ela pode ser definida por duas parcelas, uma com componente determinístico ($a + b \cdot x_t$) e outra de componente estocástica (ϵ_t). Por sua vez, a equação 2-2 apresenta de forma genérica como uma série temporal pode ser apresentada.

$$S_t = \{a_0, a_1, a_2, a_3, \dots, a_n\} \quad (2.2)$$

Diante dessa definição, quando se considera que há um maior caráter estocástico no comportamento de tais eventos, podemos atribuir essa modelagem é fenômenos de grande aleatoriedade, onde é justificável modelar a probabilidade de ocorrência.

Ao se realizar uma previsão das próximas ocorrências de uma série temporal é preciso aceitar a premissa de que os valores passados possuem influência nos valores

futuros. Apesar da disparidade em relação a definição de uma série temporal aleatória, pode-se assumir essa afirmação quando há explícita correlação entre as próprias variáveis e se considera que a abstração matemática não contempla toda a modelagem do sistema. Assim, há diversas abordagens de previsões desses conjuntos de dados, que buscam identificar padrões e minimizar os erros de previsão considerando uma margem de confiança.

Sobre o uso de séries temporais para previsão de dados de energia em edifícios, Kwok Wei Shah (2017), integrante do Departamento de Construções, da National University of Singapore, afirma:

"[...] As the time series forecasting model learns from previous energy consumption usage patterns, a gradual increase in the forecasted energy consumption values over a period of time may also notify the facility managers on the maintenance aspects of the building and energy systems."

A partir de características aleatórias e dos padrões no comportamento, Wei (2017) justifica analisar o consumo de energia como uma série temporal. Dessa forma, o conjunto de observações podem ser ordenados de acordo com a equação 2-2, principalmente quando se considera que o registro e faturamento dos gastos ocorrem em intervalos igualmente espaçados.

Tendo como base que o objeto de estudo desse documento é prever de forma estruturada como se dará o consumo de energia no mês seguinte, a partir do comportamento passado, a abordagem orientada a dados modelada como uma série temporal se torna coerente para garantir melhor eficiência nas tomadas de decisões de profissionais responsáveis pela gestão de energia em prédios públicos e aumentar a velocidade de ateste das faturas.

Todavia, o algoritmo que prevê a resposta de determinada grandeza não garante total confiabilidade desse dado. Ele deve ser utilizado para se comparar um valor esperado com o valor real e emitir sinais dessa variável para julgamento do profissional responsável.

Como foi exposto, o comportamento do consumo de energia pode ser decomposto em um carácter aleatório e outro sazonal. Quando se avalia o consumo no

curto prazo, a componente estocástica tende a prevalecer em detrimento da componente determinística/sazonal. Essa composição intrínseca, que relacionada aleatoriedade com padrões correlacionados, leva a série temporal ser uma boa modelagem para o consumo de energia com o objetivo de se realizar previsões.

2.3.2. Métodos de previsão de curto prazo

Segundo Hosch (2020), editor da enciclopédia Britannica, o aprendizado de máquina, sendo considerado como uma área de engenharia e ciência, consiste em metodologias de que dão aos computadores capacidade de aprender e serem mais precisos, sem a necessidade de serem explicitamente programados. De acordo com a Google Inc. (2020), isso é possível na estruturação de algoritmos que são capazes de realizar verificações em seus resultados e tomar decisões previamente estabelecidas para otimizar os resultados futuros.

De forma geral, a capacidade de aprendizado de máquina está diretamente ligada à otimização dos resultados para o qual um algoritmo foi projetado. Ao considerar uma série temporal como o consumo de energia, cujos dados históricos apenas crescem no tempo, pode-se realizar uma analogia ao processo de aprendizado de máquina. Isso porque espera-se que o método se torne cada vez mais preciso à medida que novas informações descrevam o comportamento do objeto de estudo, pela própria definição de aprendizado de máquina.

A abordagem desse trabalho se reserva em identificar o consumo de curto prazo, para garantir informações relevantes no momento da avaliação de conformidade da unidade consumidora. Nesse sentido, considera-se de curto prazo a próxima ocorrência da série temporal dos dados coletados. Como os eventos estudados são mensais (faturamentos de consumo de energia), a previsão espera identificar o valor do próximo faturamento para a unidade consumida como um todo.

Diante do exposto, torna-se um problema de regressão. Dadas variáveis de entrada x , espera-se obter uma variável y contínua como saída. No caso do problema de gestão de faturas proposto no tópico 2.2, a modelagem abordada trata apenas de uma

variável de grandeza elétrica, consumo de energia em (kWh). Por sua vez, o valor de saída é também o consumo energético, de mesma unidade. Além disso, o objetivo desse trabalho é elaborar um método confiável de validação e gestão do consumo, de fácil empregabilidade e reprodutibilidade.

Wei, et al. (2017), em seu estudo, mostrou que algumas das abordagens orientadas à dados para realizar previsões são Redes Neurais Artificiais (ANN), Máquina de Vetores de Suporte (SVM), Regressões Estatísticas e Clusters. Modelos como ANN e SVM são considerados como *deep learning*, ou seja, algoritmos que tentam modelar abstrações de alto nível de dados usando uma estrutura profunda com várias camadas de processamento.

Com relação à implementação, esses algoritmos são considerados mais complexos e demorados para realizações dos cálculos. Zhao & Magoulès (2012), apontam um bom resultado de previsão em sua obra “A review on the prediction of building energy consumption”. Os autores ainda concluem:

“Elaborate and simplified engineering methods, statistical methods, artificial intelligence, especially neural networks and support vector machines, are widely used models.”

Em relação ao modelo de redes neurais artificiais, Zhao & Magoulès (2012) afirmam que seu uso é recomendado para resoluções de problemas não lineares. Por fim, o estudo desse modelo ao longo do tempo aborda a previsão de energia em diferentes tipos de consumo:

“In the past twenty years, researchers have applied ANNs to analyze various types of building energy consumption in a variety of conditions, such as heating/cooling load, electricity consumption, sub-level components operation and optimization, estimation of usage parameters”

As redes neurais podem ser empregadas para o processo de previsão de energia quando devidamente treinadas e validadas. São modelos robusto e que dependem de várias variáveis de entrada.

- **Redes Neurais Artificiais**

Wei, et al. (2017) conceitua que as ANN são estruturadas pensando na arquitetura do cérebro humano. A rede consiste em um grande número de unidades de processamentos, neurônios, organizadas em camadas. Uma camada se conecta a outra através das conexões entre neurônios.

Cada unidade de processamento lida com um sinal $x_{il}(i = 1, 2, \dots, m)$ das unidades de processamento das camadas anteriores. Esses sinais entram para a próxima conexão associados com pesos $w_{il}(i = 1, 2, \dots, m)$.

A figura 2-1 ilustra o fluxo de processamento de uma unidade. Nela, é possível verificar que a saída sofre influência da função de ativação e do viés (bias). Em síntese, o cálculo passa por uma sumarização e é somado a uma constante b , que é responsável por ajustar e parametrizar o resultado para função de ativação. Por sua vez, a função de ativação, usualmente utilizada a função sigmoide (curva logística), tem a função de ativar o valor de saída da unidade de processamento, atribuindo ao resultado um valor entre 0 e 1. As equações 2.3 e 2.4 se referem as funções de sumarização e de ativação, respectivamente.




Figura 2-1 - Esquema interno de um neurônio (Fonte: O autor)

$$y_l = f\left(\sum_{i=1}^m w_{il}wx_i + b_l\right) \quad (2.3)$$

$$f(x) = \frac{1}{1+e^x} \quad (2.4)$$

O resultado desse cálculo é utilizado como entrada para a unidade de processamento da próxima camada, conectada ao neurônio l .

Ainda sobre as ANN, Wei, et al. (2017) afirma que, “independentemente da arquitetura utilizada, as redes precisam ser treinadas para o ajuste os pesos e dos vieses, antes de serem utilizadas de forma efetiva”. Esse processo de treinamento aproveita os dados históricos das variáveis de entrada e realiza cálculos iterativos para a devida modelagem.

Considerando que a base de dados empregada contará apenas com dados de consumo de energia ao longo do tempo, o uso de *shallow learning* a partir de modelos regressivos podem apresentar bons resultados. Por definição, esse método se caracteriza pela oposição aos métodos de *deep learning* e sua alta complexidade.

Playe & Stoven (2020), no estudo comparativo entre *deep* e *shallow learning*, afirmam:

“However, on small datasets, shallow methods present better prediction performance than deep learning methods”

Nesse sentido, o erro das regressões em pequenos conjuntos de dados se mostra menor do que a de algoritmos pouco treinados. Os modelos regressivos buscam encontrar uma dada função Y que melhor se ajusta ao comportamento da série de dados. Assim, os *inputs* do sistema de previsão podem se resumir aos dados da série temporal, sem a necessidade de integrações em camadas abstratas de aprendizado. A figura 2-2 retrata como exemplo a regressão linear de determinados pontos, que ilustra um dos métodos de *shallow learning*.




Figura 2-2 - Ilustração genérica de um modelo *shallow learning*. (Hyndman & Athanasopoulos, 2018)

Dentre os principais métodos de *shallow learning*, pode-se destacar: média móvel simples, média móvel exponencial, regressão linear, regressão polinomial, ARIMA e suavização exponencial. Esses métodos abordam esturradas lógicas para realizar a previsão e possui como característica a fácil implementação.

Segundo Martins & Laugeni (2005), os métodos empregados para as previsões de vendas também consideram apenas os dados históricos. A partir da obra “Administração da Produção”, seguem alguns conceitos estatísticos dos modelos de previsão, que serão abordados no trabalho quando necessária a devida implementação.

- **Média móvel simples**

Martins & Laugeni (2005) definem que, na média móvel simples, a previsão no período futuro t é calculada como sendo a média de n períodos anteriores. Deve-se escolher quantos períodos a média será calculada.

A aplicação da média móvel simples resulta na sequência das médias das subsequências de n elementos da sequência. Dessa forma uma sequência de m

elementos $P = (p_1, \dots, p_m)$, o cálculo de um termo qualquer da sequência resultante pela média móvel é dado pela equação 2.5.

$$\bar{P}_t = \frac{p_{i+1} + \dots + p_{i+n}}{n} \quad (2.5)$$

A média móvel simples possui 3 formas de ser aplicada: considerando-se os n elementos posteriores, futuros como foi feito acima; os n elementos anteriores, passados (como em séries temporais); ou considerando-se ainda elementos anteriores e posteriores. Neste último caso, apenas $n/2$ elementos devem ser adicionados aos dois extremos.

A quantidade n de termos depende diretamente da quantidade de dados amostrado e esse método não depende do cálculo de parâmetros. O termo P é o resultado esperado para o valor da série temporal do termo índice t

- **Média móvel exponencial**

Por sua vez, no método de média móvel como ajustamento exponencial, Martins & Laugeni (2005) afirmam que “a previsão P é calculada a partir da última previsão realizada no período $(t - 1)$ adicionada ou subtraída de um coeficiente α que multiplica o dado real (C)”. A previsão no período P_{t-1} de acordo com a expressão a seguir:

$$P_t = P_{t-1} + \alpha(C_{t-1} - P_{t-1}) \quad (2.6)$$

Os autores complementam que “para determinar o valor de α , este pode ser calculado em função do número de períodos n considerados para o modelo em questão”. Utiliza-se a expressão abaixo:

$$\alpha = \frac{2}{n + 1} \quad (2.7)$$

A diferença da média exponencial para a média móvel comum é que a exponencial coloca um peso maior nos dados mais recentes, enquanto os dados mais antigos ficam com pesos cada vez menores; na média móvel comum todos os dados possuem o mesmo peso. É importante se atentar para o fato de que na exponencial todos os seus pesos são potências, o que implica em uma relação não-linear entre os dados.

- **Regressão linear**

Bussab, W. D., & Morenttin, P. A. (2010), na obra Estatística Básica, afirmam que a regressão linear busca determinar a função $Y = ax + b$ que descreve o comportamento da variável Y dependente pela variável x , independente. O método para determinar os coeficientes busca minimiza o valor do erro quadrático em relação aos pontos informados.

Os valores de a e b são calculados conforme as equações 2.8 e 2.9, respectivamente.

$$b = \frac{\sum xy - n\bar{x}\bar{y}}{\sum x^2 - n(\bar{x})^2} \quad (2.8)$$

$$a = \bar{y} - \bar{x} \quad (2.9)$$

Por fim, para verificar o nível de ajustamento da reta aos dados, utiliza-se o coeficiente de correlação r . Esse coeficiente varia entre -1 e +1, indicando correlação ascendente ou decrescente.

Assim, dado um conjunto de dados, a regressão apresenta uma função que descreve o comportamento de toda a série temporal, a partir do método que reduz o erro quadrático. Pela sua característica de ajuste, a regressão se torna cada vez melhor ajustada ao sistema quanto a quantidade de registro aumenta. Isso porque os pontos fora da curva de grande divergência (outliers) se tornam cada vez mais desprezíveis.

- **Regressão polinomial**

A regressão polinomial, segundo Martins & Laugeni (2005), realiza o ajuste de uma função que modela o comportamento dos dados através de uma função Y , cujo comportamento é não linear. A função da regressão pode ser definida em termos gerais conforme a equação 2.10.

$$Y = a_0 + a_1x + a_2x^2 + \dots + a_nx^n \quad (2.10)$$

Para o ajuste do grau do polinômio, deve-se considerar a quantidade de amostra e também o esforço computacional para ajuste da curva.

A estimação dos coeficientes também ocorre pelo método dos mínimos quadrados, de forma que a derivada parcial da função em relação a cada parâmetro seja zero, conforme a equação 2.11.

$$\frac{\partial Y}{\partial a_n} = 0 \quad (2.11)$$

- **ARIMA**

O método Auto Regressive Integrated Moving Average (ARIMA) tem como objetivo explicar o comportamento de uma série temporal com base em seus valores passados. Conforme Prabhakaran (2020), ela pode ser utilizada para modelar séries temporais que não possuem comportamento sazonal.

O método é caracterizado por três termos: p , d e q , onde:

- p é a ordem do termo AR;
- q é a ordem do termo MA;
- d é o número de diferenças requeridos para deixar a série estacionária;

Segundo Hyndman & Athanasopoulos (2018), “uma série temporal com tendência ou sazonalidade não é estacionária”. Esses comportamentos podem afetar o valor da série em tempos diferentes. Por isso, realiza-se a diferença entre o próximo valor da série com o valor atual, a fim de tornar a série com comportamento estacionário.

Portanto, o parâmetro d é o número de diferenças realizadas para tornar uma série estacionária. Em uma série já estacionária, $d = 0$, por padrão.

Por sua vez, o parâmetro p se refere ao número de atrasos na função Y a ser usada como preditora. É a partir desse termo que o processo de precisão se torna móvel. Não obstante, o parâmetro q se refere ao número de atrasos do erro da predição, utilizado para no modelo de regressões do método.

A fórmula geral para o método ARIMA é dada conforma a equação 2.12.

$$Y = \alpha + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \epsilon_1 \quad (2.12)$$

Onde Y_{t-1} é o atraso 1 da série, β_1 é o coeficiente de atraso 1 e α é o intercepto no eixo Y , também estimado pelo modelo.

De forma geral, pode-se expressar o método ARIMA como:

Predição $Y = \text{Constante} + \text{Combinação linear do atraso de } Y + \text{Combinação linear do erro do atraso da previsão}$

- **Suavização exponencial**

O método de Suavização Exponencial é uma forma de descrever o comportamento de um conjunto de dados a partir da atribuição de pesos exponenciais decrescentes para as médias no tempo. Assim, o algoritmo atribui maior relevância para os valores mais recentes de uma série temporal.

Esse método é considerado de *shallow learning*, cujo procedimento é fácil de aprender e aplicar para prerrogativas de comportamento sazonal. Em síntese, o conjunto de dados é representado por x_t , que se inicia no tempo $t = 0$. O resultado do

algoritmo de precisão é comumente chamado de s_t , que por sua vez pode ser considerado a melhor estimativa para o próximo valor da variável observada.

A equação para descrever o modelo é dada por:

$$\begin{aligned} s_0 &= x_0 \\ s_t &= \alpha x_t + (1 - \alpha)s_{t-1} \end{aligned} \quad (2.13)$$

Onde α é o fator de alisamento e $0 \leq \alpha \leq 1$. Logo, a equação s_t é uma média ponderada da observação x_t e do valor anterior s_{t-1} . O fator de alisamento que melhor se adequa ao modelo é calculado a partir de validações cruzadas ou demais métodos de treino que buscam minimizar o erro quadrático de previsão considerando o resultado da observação anterior.

Quando utilizado para previsão de variáveis elétricas, fator de alisamento pode ser dado como a razão entre o tempo de amostragem e a constante de tempo do sistema em questão. Logo, esse valor se aproxima dos 63,2% da resposta ao degrau.

Ainda sobre os métodos de suavização exponencial, pode-se destacar o método de tripla suavização, também chamado de Holt Wintes. Segundo o site da SolarWinds (2019), esse método “busca modelar três aspectos de uma série temporal: A média, a tendência e a sazonalidade”.

O modelo calcula o valor futuro combinando o efeito das três influências. Para isso, ele necessita de alguns parâmetros que descrevam a média, tendência, tamanho da sazonalidade e, por fim, os períodos da sazonalidade. Por sua vez, a sazonalidade nesse modelo pode ser definida como o tamanho fixo que contém a repetição completa.

As componentes para o método são:

$$\begin{aligned} s_0 &= x_0 \\ s_t &= (\alpha x_t - c_{t-L}) + (1 - \alpha)(s_{t-1} + b_{t-1}) \\ b_t &= \beta (s_t - s_{t-1}) + (1 - \beta)b_{t-1} \\ c_t &= \gamma(x_t - s_{t-1} - b_{t-1}) + (1 - \gamma)c_{t-L} \end{aligned} \quad (2.14)$$

Onde s_t representa o valor suavizado para o tempo t , b_t é a sequência dos melhores valores estimados para a tendência linear, c_t é a sequência de correções sazonais e L é o período de sazonalidade completo.

2.4. Validação Cruzada

A validação cruzada é um método de estimação amplamente utilizado para avaliar o erro de predições e a capacidade de generalização de um modelo, a partir de um conjunto de dados.

O conceito central das técnicas de validação cruzada é o particionamento do conjunto de dados em subconjuntos mutuamente exclusivos, e posteriormente, o uso de alguns destes subconjuntos para a estimação dos parâmetros do modelo (dados de treinamento), sendo os subconjuntos restantes (dados de validação ou de teste) empregados na validação do modelo.

A Google Inc. (2020) define os conjuntos de dados como:

“Conjunto de treino – um subconjunto dos dados usado para treinar o modelo;

Conjunto de teste – um subconjunto dos dados usado para testar e treinar o modelo;

Conjunto de validação – um subconjunto dos dados (desassociado ao conjunto de treino) usado para realizar a validação.”

Para realizar o particionamento de um único conjunto de dados em treino e teste, torna-se necessário validar os seguintes pontos:

- Se o conjunto de dados é grande o suficiente para possuir resultados estatísticos significantes;
- Se o conjunto de teste representa o conjunto de dados principal de forma completa, ou seja, contempla as diversas características do conjunto de dados principal.




Figura 2-3 - Validação do modelo de treino sobre o modelo de teste. (Google Inc., 2020)

A figura 2-2 apresenta um modelo genérico para separação dos dados em seus respectivos conjuntos de treino e teste. A partir dessa imagem, torna-se possível identificar o objetivo do particionamento, para obter uma amostra que representa os dados com suas principais características.

Ainda sobre os conjuntos, o objetivo da divisão é justamente evitar encontrar resultados com alto nível de precisão, mas que não representam os dados em sua integridade. Segundo Shah (2020), resultados extremamente positivos em relação à métrica de análise pode indicar que houve sobreajuste e, acidentalmente os dados foram treinados no conjunto de teste.




Figura 2-4 - Visualização dos grupos de dados de forma genérica. (Shah, 2020)

A figura 2-4 é uma representação genérica de como os dados são particionados em grupos. O principal objetivo desta divisão é calcular os parâmetros do método que mais se ajustam ao comportamento do objeto a ser previsto. O conjunto de validação são os dados utilizados para prover uma análise sem vieses do ajuste do modelo enquanto encontra o *hyperparameter* do mesmo. Por fim, o conjunto de teste é utilizado para encontrar o melhor método de previsão e evitar o sobreajuste (*overfitting*).

Satyam Kumar (2020) aborda diferentes tipos de validações cruzadas em seu artigo. Dentre elas, destacam-se três que possuem vantagens com relação à implementação, baixo viés e utilização de todo o conjunto de dados. Os métodos são: holdout, k-fold, leave-one-out.

- **Método holdout**

O método de validação cruzada holdout consiste em segmentar o conjunto de dados em dois subconjuntos mutuamente exclusivos, um para o treinamento (estimação dos parâmetros) e outro para teste (validação). Dessa forma, o método evita o vício das previsões ao conjunto de teste, chamado de sobreajuste.

Após o particionamento, a estimação do modelo é realizada e, posteriormente, os dados de teste são aplicados e o erro de predição calculado. Esta abordagem é indicada quando está disponível uma grande quantidade de dados. Caso o conjunto total de dados seja pequeno, o erro calculado na predição pode sofrer muita variação.

Satyam Kumar (2020) ainda complementa que, “quanto maior é a quantidade de dados disponíveis, melhor é o modelo. Para esse método, uma grande quantidade de dados é isolada do conjunto de treino.

- **Método k-fold**

O método *k-fold*, por sua vez, já foi abordado para previsão de energia no estudo de Tabrizchi, Javidi, & Amirzadeh (2019). Nele, os autores concluem que o uso do método teve um resultado satisfatório para a previsão de energia de edifícios.

Na validação cruzada de *k-fold*, a massa de dados é particionada em k grupos de tamanhos iguais. Cada um dos k grupos são utilizados para medir a acurácia do método de previsão e os outros $k-1$ grupos são utilizados para construir o modelo.

O erro resultante de cada grupo k , em geral, é utilizado para calcular a média do erro final. Nesse sentido, uma das vantagens da validação cruzada é que todos os dados utilizados no processo, seja treino e teste, podem ser computados k vezes. Portanto, o erro quando se utiliza a validação cruzada tem menor variância quando se comparado ao grupo apenas de treino e de teste.

- **Método *leave-one-out***

O método *leave-one-out* é um caso específico do *k-fold*, com k igual ao número total de dados N . Ainda segundo Satyam Kumar (2020), esse método é uma técnica exaustiva para validação. Nesta abordagem são realizados N cálculos de erro, um para cada dado.

Apesar de apresentar uma investigação completa sobre a variação do modelo em relação aos dados utilizados, este método possui um alto custo computacional, sendo indicado para situações onde poucos dados estão disponíveis.

2.4.1. Sobreajuste

O conceito de sobreajuste, em estatística, é o resultado de uma análise que corresponde apenas a um conjunto de dados em particular, sendo que essa mesma análise falha na previsão de outros conjuntos.

Segundo Malato (2020), o sobreajuste “ocorre quando o algoritmo guarda informações dos dados de treino e não é capaz de generalizar essa informação para dados externos”. Em síntese, o resultado de uma previsão de uma modelo sobreajustado é a menor variação residual possível para apenas um conjunto de dados.

O sobreajuste está diretamente ligado ao método de treino do modelo de previsão. A possibilidade do resultado ser enviesado pelos dados ocorre quando o

conjunto de dados de treino é o mesmo conjunto de dados para realizar os testes. Assim, o modelo “memoriza” os dados do treino em vez de aprender com eles, para replicar o método em outro conjunto. O potencial de sobreajuste depende não só do número de parâmetros do modelo, mas também da conformidade do modelo com a estrutura dos dados.

2.4.2. Subajuste

Por sua vez, o subajuste ocorre quando o modelo não consegue capturar a estrutura do conjunto de dados, ou seja, o algoritmo não se ajusta aos dados e produz um grande erro de predição, mesmo com uma pequena variância. Segundo Koehrsen (2018), esse modelo ignora aspectos importantes de crescimento e sazonalidade do conjunto de dados.

Koehrsen (2018) ainda complementa:

“[...] an underfit model has low variance and high bias. Variance refers to how much the model is dependent on the training data. [...] The model failed to learn the relationship between x and y because of this bias, a clear example of underfitting.”

O resultado de um modelo subajustado não é sustentável para aplicações, pois sempre gera resultados de grande divergência ao valor esperado.

2.4.3. Regularização

Segundo Gupta (2017), “a regularização de um modelo estatístico é o processo utilizado para reduzir o erro de predição ajustando a função apropriadamente no conjunto de dados de treino, evitando o risco de sobreajuste”.

Para isso, a regularização adiciona à função de erro dados adicionais, para que os coeficientes da função não assumam valores extremos. Gupta (2017) ainda conclui:

“[...] this technique discourages learning a more complex or flexible model.”

Há situações que o modelo se ajusta aos dados de treino, mas ele falha ao generalizar a função para dados intermediários. Conforme a figura 2-5, a curva verde representa os dados reais e os pontos são o conjunto de dados coletados. Por sua vez, a curva vermelha é o ajuste por um método de regressão. A partir do quarto gráfico, torna-se evidente a necessidade de adicionar dados para melhor compor a função de erro.




Figura 2-5 - Ajuste polinomial de diferentes ordens para uma função senoide (Towards Data Science, 2018)

O termo regularizador é adicionado à função de custo, conforme a equação 2-15.

$$\min_f \sum_{i=1}^n \gamma(f(x_i), y_i) + \lambda R(f) \quad (2.15)$$

Onde γ representa a função de custo da variável a ser prevista em relação ao seu valor de referência. $R(f)$ se refere ao termo regularizado enquanto λ é um coeficiente para controlar a importância da regularização.

Diante do exposto, identifica-se que o processo de regularização pode auxiliar em modelos de previsão, tornando-os mais sofisticados e com comportamento mais próximo do esperado. É uma ferramenta importante a ser considerada em situações cujo conjunto de dados é pequeno e se enfrenta dificuldades em descrever comportamentos-chaves desses elementos.

2.4.4. Hyperparameters

Segundo Claesen & De Moor (2015), a pesquisa voltada para o aprendizado de máquina foca em métodos capazes de capturar elementos-chaves de um determinado conjunto de dados. Essas informações são utilizadas para previsão ou modelagem de determinado fenômeno.

Algo comum na grande variedade de métodos de previsão é que eles são parametrizados por um conjunto de hyperparameters. Em geral, esses parâmetros são escolhidos pelo usuário após testes que maximizam a capacidade de aprendizado de máquina. Ainda conforme Claesen & De Moor (2015):

“Hyperparameters are usually of continuous or integer type, leading to mixed-type optimization problems. Continuous hyperparameters are commonly related to regularization”.

Assim, a otimização de *hyperparameter* pode contribuir em minimizar a função de custo de um modelo de previsão. Para não ser uma medida empírica, existem pacotes de *software* com implementação dedicada à busca do *hyperparameter*. Esses pacotes, em geral, são destinados ao uso em sinergia com bibliotecas de aprendizado de máquina.

Capítulo 3

Metodologia

Para a análise e previsão do consumo energia de prédios públicos de Minas Gerais, Brasil, serão utilizados os dados coletados dos imóveis do Tribunal Regional do Trabalho da 3ª Região, no período de junho de 2018 a dezembro de 2020. Sobre sua gestão, até o momento da coleta dos dados, haviam 84 prédios. Cada construção possui diversas instalações elétricas que compõem o consumo energético da unidade.

3.1. Base de dados

O primeiro passo foi estruturar os dados de consumo de energia em uma base de dados e garantir o devido preenchimento dessas informações. A base foi estruturada de forma relacional.

Dessa forma, considera-se o prédio como uma unidade consumidora que possui suas respectivas instalações. Cada instalação, por sua vez, possui faturas que são registradas mensalmente. Com isso, a principal tabela a ser estudada contém registro das informações de consumo de energia, associados a um número de instalação que por sua vez está associado a um imóvel (unidade consumidora).

A Figura 3-1 mostra o esquema relacional da base de dados. As análises e estudos desse documento consideram apenas a parte de energia. Dentre as colunas da tabela “*nf_energia*”, existem medidas que são referentes apenas a instalações de média tensão. Para contemplar as análises em um mesmo estudo, a coluna de Energia Ativa em Horário Fora de Ponta (EA HFP) foi escolhida para ser o consumo de energia das instalações de baixa tensão.




Figura 3-1 - Esquema da Base de Dados Relacional

A coleta estruturada dos dados foi implementada por um código em *Visual Basic for Applications*, disponível em planilhas Excel. Por se tratar de dados brutos, eles seriam depois analisados em softwares de *Analytics*.

Para esse trabalho, será utilizado o campo de Energia Ativa em Horário Fora de Ponta. Com esse estudo, espera-se poder inferir que o método escolhido pode ser empregado aos demais campos da tabela, respeitando os conceitos de treino e validação cruzada. Entende-se que a inferência respeita os conceitos de previsão, visto que todos os campos da tabela estão diretamente relacionados, se não por apenas uma constante.

3.1.1. Edifícios de interesse

As unidades consumidoras de interesse foram avaliadas conforme a quantidade de registros disponíveis para estudo. O histórico disponibilizado pela concessionária era

de no máximo dois anos. Assim, foram selecionados os prédios com maior série história de suas instalações para implementar os testes com algoritmos de previsão. A abordagem nas demais unidades podem ser implementadas de forma análoga. A Tabela 3.1 apresenta as unidades consumidoras e seus respectivos identificadores.

Tabela 3-1 - Edifícios de interesse Tribunal Regional do Trabalho 3ª Região

ID IMÓVEL	ENDEREÇO	MUNICÍPIO	NÚM. REGISTROS
1BHZ202	Rua Mato Grosso, 468	Belo Horizonte	28
1BHZ110	Avenida Getúlio Vargas, 225	Belo Horizonte	28
1BHZ109	Avenida Getúlio Vargas, 265	Belo Horizonte	28
1BHZ108	Rua Goitacazes, 1475	Belo Horizonte	28
1BHZ103	Avenida Amazonas, 3010	Belo Horizonte	28
3CEL101	Rua José Gomes Ferreira, 90	Coronel Fabriciano	29
2DIV101	Rua Pernambuco, 239	Divinópolis	28
7MCL101	Avenida Major Alexandre Rodrigues, 65	Montes Claros	30
5PSS101	Rua Antônio José dos Santos, 135	Passos	30
5PAG101	Avenida Coronel Armando Rubens Storino, 2715	Pouso Alegre	30
2STL101	Alameda Ismael Martins, 101	Sete Lagoas	30
6UBB101	Avenida Maria Carmelita Castro Cunha, 60	Uberaba	28
6UBL101	Avenida Cesário Alvim, 3200	Uberlândia	28

3.2. Análises iniciais

Rallapalli, S. R., & Ghosh (2012), no estudo sobre previsão do pico de demanda de energia elétrica, inicialmente apresentam algumas observações estatísticas sobre o conjunto de dados abordado. Dentre essas medidas de análise inicial, os primeiros parâmetros extraídos são: média aritmética e variância/desvio padrão, além do valor máximo e mínimo.

A média pode ser utilizada para nortear os estudos com um valor que representa a proporção de excesso de um número avaliada sobre os demais dados. A partir desse valor, calcula-se a variância e o desvio-padrão.

O resultado desses cálculos representa uma medida de dispersão em torno da média de uma variável aleatória. Ela também auxilia na condução dos estudos de previsão para realizar a devida análise do resultado. Quando um conjunto de dados já apresenta grande variação, espera-se que o modelo de previsão linear apresente maiores resíduos ao final de sua análise.

Ademais, as primeiras avaliações do conjunto de dados de energia serão realizadas com descrições de quantidade de períodos e cálculos estatísticos básicos. A partir desses primeiros resultados, iniciará uma abordagem mais voltada ao algoritmo de previsão. Isso porque as características inerentes de um conjunto de dados são de fundamental importância para a escolha do método que melhor se ajusta aos dados.

3.3. Implementação

O algoritmo será implementado em linguagem R ou Python. Esses ambientes de programação são largamente usados entre estatísticos e analistas de dados para desenvolver softwares de estatística. Existem diversos pacotes de previsão prontos já desenvolvidos, inclusive em suas bibliotecas padrão.

A partir da aplicação de cada método de previsão na mesma base de dados, respeitando o ambiente de treino e os conceitos de validação cruzada, torna-se possível realizar um estudo para comparar o melhor método para previsão do consumo energético.

Todavia, a quantidade de dados registrados se mostra pequena em relação aos estudos já empregados. Amasyali & El-Gohary (2017), no artigo "*A review of data-driven building energy consumption prediction studies*", exibem em tabela comparativa o tamanho dos conjuntos de dados já empregados para desenvolvimento dos modelos de previsão em outros estudos. Segundo os autores, a maior parte das abordagens de previsão relacionadas a energia se concentram nos registros intra-hora com modelos de redes neurais.

Nesse sentido, um maior conjunto de dados para se realizar as devidas divisões entre os conjuntos de treino e teste poderá ser mais confiável. Considerando que os

registros dos dados do Tribunal Regional do Trabalho são mensais e até o momento carecem de uma longa série histórica, uma estratégia para implementação do modelo seria aumentar a quantidade de dados disponíveis ou a busca de uma outra base de dados, com características semelhantes, porém com maiores informações. A ampliação dos registros da base do TRT3 é influenciada pelo fator temporal de coleta, portanto, torna-se mais viável a implementação utilizando uma base de dados externa.

Assim, após o estudo e validação do método em uma base de dados externa, torna-se possível realizar uma comparação ou inferência ao comportamento de consumo energético dos prédios públicos do TRT3 e buscar uma futura implementação.

Por fim, espera-se utilizar como parâmetro para avaliar a precisão de um método o valor do erro quadrático. Esse erro será calculado considerando o último valor registrado da série temporal.

Capítulo 4

Conclusões

O presente trabalho teve início com a necessidade de estruturar a coleta de dados de energia dos prédios públicos do Tribunal Regional do Trabalho 3ª Região e realizar uma previsão dos dados para auxílio da gestão interna. A partir dessa motivação, estudou-se a relevância da análise do consumo energético e da gestão das despesas de energia.

Com relação ao consumo energético de prédios, verificou-se que a grande parte dos gastos estão associados ao sistema de iluminação e de ar condicionado. A partir dessa informação, foi identificada a oportunidade de realizar um controle do consumo de energia e a previsão para o mês vigente, a fim de ser utilizada como possível sinalizador de problemas do edifício e incentivar manutenções preventivas.

Em relação à gestão dos gastos, a composição mista das faturas de um edifício, somada a quantidade de construções são fatores que dificultam a análise do consumo de energia para o setor administrativo. Além disso, tendo em vista o carácter jurídico do ateste, fica concentrado ao gestor público informar se o serviço foi prestado de maneira correta. Assim, diante de dados estruturados sobre os gastos das unidades consumidoras, o servidor responsável pelo contrato pode tomar ações para minimizar o desprendimento de capital com multas e juros de atrasos.

Foi desenvolvida uma pesquisa em relação a previsão de dados de energia elétrica em prédios. Constata-se que algoritmos como Redes Neurais Artificiais, Máquinas de Vetores e Suporte e métodos regressivos já foram empregados para a predição de dados de energia. Assim, tanto uma abordagem de *deep learning* como *shallow learning* podem garantir bons resultados. Enquanto os modelos de *deep learning* necessitam de uma grande quantidade de dados para realizar as abstrações e correlacioná-los, os modelos de *shallow learning* apresentam bons resultados para conjuntos de dados menores, segundo a revisão bibliográfica. Também foi possível

justificar o uso de séries temporais para modelar o registro do histórico do consumo de energia.

O delineamento da pesquisa foi desenhado para apresentar a estruturação da base de dados e as características para implementação. Considerando os aspectos da base do TRT3 e os outros estudos que abordam a previsão de dados de energia em edifícios, conclui-se que a quantidade de registros é pequena para se empregar os conceitos de aprendizado de máquina, mesmo os métodos de *shallow learning*. Isso se justifica principalmente pela pequena amostragem para particionar os conjuntos da validação cruzada. Assim, espera-se utilizar outro conjunto para implementação, a fim de realizar associações e inferências em relação ao comportamento de prédios públicos do TRT3.

Portanto, a estruturação dos dados de energia gera benefícios para a gestão pública, evitando gastos com atrasos e abre a possibilidade do estudo de modelagem e previsão. Em relação à precisão do algoritmo a ser implementado, é necessário um maior conjunto de dados para se obter um resultado mais eficiente, evitando que o algoritmo memorize comportamentos específicos da amostragem. Por fim, será elaborado um material com a implementação do algoritmo de previsão e as análises considerando os conceitos aqui apresentados.

Referências Bibliográficas

- ABESCO. (27 de dezembro de 2020). *O que é Eficiência Energética? (EE)*. Fonte: Associação Brasileira das Empresas de Serviços de Conservação de Energia: <http://www.abesco.com.br/pt/o-que-e-eficiencia-energetica-ee/#:~:text=Efici%C3%Aancia%20energ%C3%A9tica%20%C3%A9%20uma%20atividade,se%20obter%20um%20determinado%20resultado>.
- Amasyali, K., & El-Gohary, N. M. (27 de abril de 2017). A review of data-driven building energy consumption prediction studies. *Renewable and Sustainable Energy Reviews*, pp. p. 1192–1205.
- ANEEL, A. N. (03 de abril de 2012). *RESOLUÇÃO NORMATIVA Nº 479, DE 3 DE ABRIL DE 2012*. Fonte: AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA - ANEEL: <https://www.aneel.gov.br/documents/656877/14486448/ren2012479.pdf/a89312fe-a5d7-4151-96be-95765ea2ce03?version=1.0>
- Bussab, W. D., & Morenttin, P. A. (2010). *Estatística Básica*. São Paulo: Editora Saraiva.
- Claesen, M., & De Moor, B. (6 de abril de 2015). Hyperparameter Search in Machine Learning. *The XI Metaheuristics International Conference*, pp. p. 14-1 - 14-5.
- Costa, A. F. (03 de novembro de 2020). *Fiscal de contratos administrativos: atribuições*. Fonte: JUS: <https://jus.com.br/artigos/24855/aspectos-gerais-sobre-o-fiscal-de-contratos-publicos/2#:~:text=LIQUIDA%C3%87%C3%83O%20DA%20DESPESA&text=%E2%80%9CA%20liquida%C3%A7%C3%A3o%20da%20despesa%20consiste,cumprir%20o%20que%20foi%20pactuado>
- d’Albuquerque, M. A., Silva, R. M., & Gomes, M. B. (11 de outubro de 2017). EFICIÊNCIA ENERGÉTICA EM UMA EDIFICAÇÃO PÚBLICA:. *Sistemas & Gestão*, pp. pp 462-470.
- Downing, D., & Clark, J. (2006). *Estatística Aplicada*. 2 ed. São Paulo: Editora Saraiva.
- Gonçalves, A. C. (2012). *Eficientização Energética Em Prédios Públicos: Um Desafio Aos Gestores Municipais Frente Aos Requisitos De Governança E Sustentabilidade. Tese de Mestrado*, pp. 1-25.

- Google Inc. (18 de janeiro de 2020). *Machine Learning Crash Course*. Fonte: Developers Google: <https://developers.google.com/machine-learning/crash-course/training-and-test-sets>
- Gupta, P. (15 de novembro de 2017). *Regularization in Machine Learning*. Fonte: Towards Data Science: <https://towardsdatascience.com/regularization-in-machine-learning-76441ddcf99a>
- Hosch, W. L. (24 de fevereiro de 2021). *Machine learning*. Fonte: Encyclopædia Britannica: <https://www.britannica.com/technology/machine-learning>
- Hyndman, J. R., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. Melbourne, Australia.: OTexts.
- INEE. (03 de novembro de 2020). *O que é Eficiência Energética*. Fonte: Instituto Nacional de Eficiência Energética: http://www.inee.org.br/eficiencia_o_que_eh.asp?Cat=eficiencia
- Koehsen, W. (28 de janeiro de 2018). *Overfitting vs. Underfitting: A Complete Example*. Fonte: Towards Data Science: <https://towardsdatascience.com/overfitting-vs-underfitting-a-complete-example-d05dd7e19765>
- Kumar, S. (13 de setembro de 2020). *Understanding 8 types of Cross-Validation*. Fonte: Towards Data Science: <https://towardsdatascience.com/understanding-8-types-of-cross-validation-80c935a4976d>
- Martins, P., & Laugen, F. P. (2005). *Administração da Produção*. São Paulo: Editora Saraiva.
- Mishra, M. (26 de maio de 2018). *REGULARIZATION: An important concept in Machine Learning*. Fonte: Towards Data Science: <https://towardsdatascience.com/regularization-an-important-concept-in-machine-learning-5891628907ea>
- Playe, B., & Stoven, V. (10 de fevereiro de 2020). Evaluation of deep and shallow learning methods in chemogenomics for the prediction of drugs specificity. *Journal of Cheminformatics* 12.
- Prabhakaran, S. (17 de dezembro de 2020). *Machine Learning Plus*. Fonte: ARIMA Model – Complete Guide to Time Series Forecasting in Python: <https://www.machinelearningplus.com/time-series/arima-model-time-series-forecasting-python/>

- PROCEL. (15 de 10 de 2020). *Edificações*. Fonte: Procel Info: <http://www.procelinfo.com.br/main.asp?TeamID=%7B82BBD82C-FB89-48CA-98A9-620D5F9DBD04%7D#:~:text=O%20Procel%20promove%20a%20avalia%C3%A7%C3%A3o,edifica%C3%A7%C3%B5es%2C%20a%20Etiqueta%20PBE%20Edifica.>
- Rallapalli, S. R., & Ghosh, S. (6 de abril de 2012). Forecasting monthly peak demand of electricity in India - A critique. *Energy Policy*, pp. p. 516–520.
- Shah, T. (05 de janeiro de 2020). *About Train, Validation and Test Sets in Machine Learning*. Fonte: Towards Data Science: <https://towardsdatascience.com/train-validation-and-test-sets-72cb40cba9e7>
- Solar, I. E. (18 de fevereiro de 2019). *Como entender sua conta de luz?* Fonte: Ideal Energia Solar: <https://idealenergiasolar.com.br/como-entender-a-sua-conta-de-luz/>
- SolarWinds. (15 de dezembro de 2019). *Holt-Winters Forecasting Simplified*. Fonte: Orange Master: [https://orangematter.solarwinds.com/2019/12/15/holt-winters-forecasting-simplified/#:~:text=Holt%20Winters%20is%20a%20model,cyclical%20repeating%20pattern%20\(seasonality\).](https://orangematter.solarwinds.com/2019/12/15/holt-winters-forecasting-simplified/#:~:text=Holt%20Winters%20is%20a%20model,cyclical%20repeating%20pattern%20(seasonality).)
- Tabrizchi, H., Javidi, M. M., & Amirzadeh, V. (08 de abril de 2019). Estimates of residential building energy consumption using. *Evolving Systems*.
- Wei, Y., Zhangb, X., Shi, Y., Xia, L., Pan, S., Wu, J., . . . Zhao, X. (26 de Setembro de 2017). A review of data-driven approaches for prediction and classification of. *Renewable and Sustainable Energy Reviews*, pp. 1-21.
- Zhao, H.-x., & Magoulès, F. (27 de Abril de 2012). A review on the prediction of building energy consumption. *Renewable and Sustainable Energy Reviews*, pp. 1-7.