

Previsão do Consumo Energético de Prédios Públicos por Rede Neural Artificial MLP

COELHO, Evandro
ALMEIDA, Cássia; ALMEIDA, Gustavo.

Resumo – No âmbito do consumo energético em prédios públicos existe a necessidade do registro estruturado dos gastos de energia para controle interno. A previsão de curto prazo, que considera aspectos históricos de comportamento das unidades consumidoras, auxilia na gestão das faturas e no devido ateste do serviço prestado, que fica sobre responsabilidade do fiscal do contrato público. Essa pesquisa se propõe realizar um estudo de previsão de dados de energia no setor público, além de uma revisão bibliográfica da área. O trabalho utiliza os dados da base *Building Sites Power Consumption*, disponível na plataforma Kaggle por Möbius (2021). A metodologia consiste na escolha do edifício de interesse, pré-processamento dos dados e previsão. Utilizou-se a arquitetura da rede neural artificial *Multilayer Perceptron* (MLP) como algoritmo de aprendizado de máquina. Ainda, foi realizada a validação cruzada *k-fold* para treinamento do modelo. Dentre as variações dos recursos de entrada e a quantidade de neurônios na única camada oculta, a combinação que melhor performou obteve R^2 de 0,86773 para o teste do modelo em base de dados desconhecida e se demonstrou capaz de generalizar o aprendizado para realizar previsões.

Palavras-chave – Previsão de consumo energético de curto prazo. Gestão de faturas de energia. Prédios públicos.

I. INTRODUÇÃO

Em relação ao suprimento e consumo de energia elétrica, o conceito de eficiência energética visa o desenvolvimento de projetos considerando as perdas em equipamentos elétricos. Ademais, existe também a demanda de otimização dos gastos de energia obtendo sinais internos de consumos ineficientes.

Exemplos de ineficiência energética ocorrem com iluminações em ambientes sem utilização, sistemas de climatização desregulados, correntes de fuga em instalações antigas etc. Como consequência direta do consumo ineficiente de energia há o maior gasto financeiro, seja por perdas em equipamentos ou desperdício.

Segundo d’Albuquerque, Silva, & Gomes (2017), no âmbito das edificações públicas, existem casos que ainda se mantêm equipamentos de alto consumo energético:

Quanto ao sistema de climatização, na maioria dos ambientes são utilizados aparelhos [...] com selo PROCEL de eficiência energética classe A, embora permaneça em uso equipamentos do tipo split com selo PROCEL de eficiência energética classe C ou, ainda, antigos sistemas de climatização de alto consumo energético.

Quando se pondera o gasto de energia de um edifício como um todo, surgem dúvidas para inferir se o consumo energético está de acordo com os valores esperados. Conforme d’Albuquerque, Silva, & Gomes (2017), analisar uma construção civil como uma grande unidade

consumidora torna-se um desafio ao avaliar os diversos fatores internos desses edifícios, como “variedade de equipamentos elétricos distribuídos pela área útil e população flutuante”.

As construções públicas de atividade laboral contam com outro fator que pode afetar o estudo do consumo de energia: a gestão dos consumos e gastos dos prédios públicos, segundo Antônio França da Costa (2020), “possuem como jurisprudência a Lei nº 8.666/1993, que se refere a liquidações de despesas públicas e ficam centralizadas aos fiscais dos contratos”. Esse mecanismo, embora siga o ritual de ateste para garantir transparência aos gastos da união, pode gerar um problema na gestão de faturas. A análise apenas dos gastos dos últimos meses carece de informações relevantes para concluir se o consumo mensal do prédio está de acordo com o que se espera.

Nesse sentido, uma das possibilidades para a análise do consumo de energia é coletar o maior intervalo possível de dados de consumo desses edifícios de forma estruturada, a fim de ser possível construir uma série temporal desses valores e buscar ferramentas de modelagem matemática para essas informações.

Como aponta Zhao & Magoulès (2012), os modelos puramente estatísticos possuem menor complexidade de implementação e boa precisão. Todavia, os autores também constatarem que os modelos de redes neurais artificiais são os mais utilizados para aplicações de previsão de energia em prédios. Os autores verificam que as Redes Neurais Artificiais (ANN) já foram utilizadas em prédios para previsões de variáveis como aquecimento solar, radiação solar e consumo energético.

Deb *et al* (2017) apresentaram em sua revisão, trabalhos de previsão de dados de curto prazo de energia com redes neurais que considerou observações intradia e correlacionava os dados com outras variáveis, como temperatura, radiação solar e população.

Esse trabalho possui como objetivo a previsão do consumo energético de curto prazo. Sua motivação está relacionada com a eficiência energética no âmbito público e na disponibilidade de dados para o auxílio da gestão pública de faturas de energia. É de competência também desse estudo a validação dos algoritmos e parâmetros para verificar o nível de precisão deles.

É de interesse que a base de dados apresente uma grande quantidade de registros para particionar os conjuntos de treino e teste, de forma que as características dos edifícios possam ser amostradas nas duas partições. Os registros de dados de prédios públicos brasileiros apresentaram limitações em relação à quantidade de medições, sendo necessária a implementação com dados externos.

Assim, foi adotada uma base de dados pública, da plataforma Kaggle, disponibilizada por Möbius (2021). Esta base possui dados estruturados de energia de edifícios, medições de temperatura, distâncias entre o ponto de medição de temperatura do prédio, contagem de feriados e área construída.

A metodologia empregada foi a de pré-processamento dos dados e implementação em uma rede neural artificial *Multilayer Perceptron*

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

(MLP). Por fim, realiza-se uma validação cruzada dos dados para identificação dos melhores parâmetros para o modelo, evitando o sobreajuste.

II. REFERENCIAL TEÓRICO

O uso da energia está presente de forma intensiva na maior parte das atividades humanas. Dentre as diversas formas de energia, as que são processadas pela sociedade e colocadas à disposição de consumidores abre um grande leque de estudos, seja na forma de gás natural, combustível, eletricidade, etc.

Com o uso extensivo de energia, passou também a se tornar preocupação e objeto de estudo o seu uso eficiente. Nesse sentido, a fim de embasar o estudo de previsão do consumo energético de prédios públicos, torna-se necessário relacionar o consumo de energia desses edifícios com a situação de gestão das despesas e uso eficiente do recurso natural.

A. Consumo Energético

A Associação Brasileira das Empresas de Serviço e Conservação de Energia (2020) define eficiência energética como “a utilização racional de energia chamada também simplesmente de eficiência energética, consiste em usar de modo eficiente a energia para se obter um determinado resultado”. Assim, está diretamente associada à eficiência dos dispositivos, que por definição consiste na relação entre a quantidade de energia empregada em uma atividade e aquela disponibilizada para sua realização.

A eficiência dos dispositivos elétricos não é a única variável que pode gerar maiores gastos energéticos. Além das perdas associadas aos equipamentos, outro fator importante de análise está relacionado com o desperdício de energia. Isso se dá principalmente pelo uso de equipamentos antigos e pouco eficientes, como já foi abordado por d’Albuquerque, Silva, & Gomes (2017).

Segundo o PROCEL (2020), “os projetos de eficiência energética, em geral, atuam em primeiro momento na substituição de equipamentos ineficientes”. Entretanto, esse método está associado ao custo de aquisição de novo material e mão de obra para implementação. Esses podem ser chamados de *retrofits*, termo utilizado para designar o processo de modernização de algum equipamento já considerado ultrapassado ou fora de norma. Um exemplo amplamente utilizado é a troca de lâmpadas fluorescentes para a tecnologia LED, que fornece intensidades luminosas maiores com menor gasto energético.

O PROCEL (2020) ainda complementa que, em relação aos edifícios, “cerca de 70% do consumo de energia se deve ao uso dos sistemas de iluminação e climatização dessas edificações”. Esse dado confirma a importância de averiguar as despesas de energia dos principais agentes consumidores com as necessidades do prédio, a fim de garantir a otimização da construção para necessidades do setor público.

Todavia, existem estratégias alternativas para se garantir maior eficiência no consumo de energia. A principal delas consiste na mudança de hábitos dos indivíduos em um ambiente de trabalho, que pode alterar o comportamento do consumo de energia.

Afrânio Gonçalves (2012), no âmbito das edificações públicas, afirma que, por se tratar de um ambiente laboral, os “estudos se concentram em avaliar as migrações de tarifas e se embasam na série histórica das instalações”, ou seja, calcula-se o consumo e a demanda média das edificações públicas para se avaliar a viabilidade de construir uma subestação própria e migrar o grupo tarifário de baixa para média tensão. Entretanto, para análise do histórico de consumo,

torna-se imprescindível a devida coleta dos dados de forma estruturada ao longo dos anos.

Segundo d’Albuquerque, Silva, & Gomes (2017), a partir dos dados, é possível “selecionar algumas das principais fontes de consumo e relacionar com, por exemplo, a quantidade de usuários no desempenho de suas funções, a quantidade de dias úteis, a quantidade de visitantes (população flutuante) ou a quantidade de novos equipamentos instalados”.

Por fim, outro fator que pode contribuir para o desperdício de recursos naturais e está ligando diretamente com os recursos financeiros é a devida gestão e análise das faturas. Ainda na obra “Eficiência Energética Em Uma Edificação Pública: Uma Análise Das Possibilidades,” d’Albuquerque, Silva, & Gomes (2017) motivam a análise da fatura energética:

A análise dos dados fornece subsídios para o planejamento e execução de ações estratégicas na gestão do consumo de energia elétrica, como a elaboração de política energética interna, a revisão de contratos e sistemas tarifários, a análise de custo-benefício da implantação de tecnologias energeticamente eficientes, o alinhamento de parcerias com universidades para estudos, realização de compras em conjunto com outros órgãos públicos, disponibilização dos indicadores de EE a todos os usuários da instituição e a sensibilização por meio de medidas de educação e de treinamento.

Assim, a correta administração das despesas pode evitar gastos com inadiplência, que afeta os gastos públicos, além de servir como indicador para problemas na infraestrutura do circuito elétrico.

Isso vai ao encontro com as atividades do fiscal do contrato público e suas responsabilidades. Dessa forma, o presente estudo também possui como fundamentação teórica o consumo energético relacionado à gestão das faturas, que por sua vez envolve a devida verificação do serviço prestado até a liquidação da despesa.

B. Gestão de Faturas

O consumo de energia elétrica em prédios públicos afeta os gastos da união. A correta análise da série histórica pode indicar alterações relativas ao consumo e, em muitos casos, pode servir como sinalizador de problemas na rede ou importantes alterações de comportamento humano. Segundo a Resolução Normativa nº414 da ANEEL, com relação aos dados do consumo energético, as contas de energia deverão conter dados de leitura de medidor, valor total a pagar e histórico de consumo de cada mês. Assim, os dados disponibilizados pela concessionária podem ser considerados insuficientes para a análise do faturamento da construção em uma janela de tempo maior.

A análise do histórico pode ser pouco eficiente para instalações individuais de baixa tensão, pois as grandes variações do consumo estão fortemente ancoradas com os hábitos de humanos do período em questão. Nesse sentido, o estudo das variações de pequenas instalações nem sempre está relacionado com um precursor de ineficiência ou problemas no circuito elétrico, como é o caso de instalações domésticas. Todavia, as características de comportamento entre os prédios públicos administrativos são semelhantes, considerando os padrões de uso e o propósito dessas edificações. Ademais, esses prédios contam com diversos circuitos que compõem uma grande unidade consumidora. Assim, adotar medidas de controle e registro da série histórica do consumo de forma estruturada é a primeira etapa de um processo visando melhorar gestão das faturas.

É necessário compreender o processo de liquidação de uma fatura de energia: segundo Antônio França da Costa (2020), auditor federal de controle externo do Tribunal de Contas da União, “o processo de

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

pagamento de uma despesa pública se inicia na fatura desse serviço”.

Como a administração pública se equipara ao consumidor final de característica jurídica para os gastos de energia elétrica, salvo a isenção fiscal, o documento que comprova o consumo chega ao fiscal do contrato público. Esse servidor, que possui fé pública e devida capacidade técnica para realizar o julgamento, atesta a fatura e reconhece que o serviço foi prestado. Citando Costa (2020):

É na fase da liquidação da despesa que o fiscal de contrato se mostra em relevo, ao atestar as medições, ao não apontar ressalvas na prestação do serviço em seus registros, ou ao apontá-las e exigir glosas nos pagamentos.

A próxima etapa é encaminhar para liquidação, para conferir documentações e por fim ocorre o efetivo crédito bancária na conta da concessionária. Costa (2020) ainda complementa que:

O objetivo da liquidação é certificar se houve o implemento da condição por parte do contratado, se ele cumpriu o que foi pactuado. A liquidação visa verificar a origem e o objeto do que se deve pagar, a importância exata a pagar, e a quem se deve pagar a importância para extinguir a obrigação.

Sobre as despesas de energia elétrica, verifica-se que a composição das notas fiscais em prédios públicos é mista, podendo ser fragmentada em diversos medidores. Apesar dessa fragmentação, as análises de gastos com energia elétrica no âmbito público podem levar em consideração o prédio administrativo como um todo. As variações apresentadas em um medidor podem ser compensadas em outra instalação da mesma construção e não seriam justificadas intervenções ou maiores análises.

É comum que um fiscal de contrato seja responsável por mais de um prédio e, por consequência, um grande número de instalações fragmentadas que geram faturas mensais. A partir dessa análise prática, pode-se considerar que uma das estratégias para o controle das despesas dessa prestação de serviço é a análise do prédio como uma instância geral, representada pelo agrupamento de todas as faturas internas. Ademais, a análise global otimiza o processo de pagamento com uma visão macroscópica do consumo energético.

Além de facilitar as análises substituindo a quantidade de variáveis com pequenas influências para entidades consumidoras gerais, torna-se possível também comparar de forma macroscópica o comportamento de sistemas semelhantes em construção e finalidade.

Portanto, torna-se uma solução mais efetiva a previsão do consumo energético do período seguinte para uma unidade consumidora composta de várias instalações elétricas. Essa informação otimiza o ritual de ateste e embasa as decisões dos fiscais dos contratos com base em uma metodologia previamente estabelecida. Como foi exposto por d’Albuquerque, Silva, & Gomes (2017), os impasses do uso eficiente de energia está na “falta de profissionais com formação especializada em EE nas instituições públicas e quanto à falta de tempo adequado em sua jornada de trabalho para dedicar-se a gestão da EE.”. De posse das informações de consumo histórico, o gestor do contrato pode tomar ações para minimizar o desprendimento de capital com multas e juros de atrasos. Ademais, essa metodologia abre espaço para novas considerações e sinaliza grandes variações do comportamento humano com o tempo.

C. Cidades Inteligentes

Da necessidade de dados estruturados e correlação com outras variáveis para previsão, a aplicação do conceito de Cidades

Inteligentes (*Smart Citys*) viabiliza os estudos de previsão.

Musa (2016) conceitua as cidades inteligentes como uma cidade que engaja a população e possui uma infraestrutura conectada de forma eletrônica. O autor ainda complementa que o objetivo de construir uma cidade conectada é utilizar a tecnologia para melhorar a qualidade de vida e prover maior eficiência nos serviços e produtos ofertados a sociedade.

No âmbito da conexão, Musa (2016) ainda aborda a coleta de dados a partir de sensores e seu processamento em tempo real:

Com o uso de sistemas de controle em tempo real e sensores, dados passaram a ser coletados e processados em tempo real (Poslad, Athen, Zhenchen & Haibo, 2015). A informação e conhecimentos coletados são a chave para identificação de ineficiência, que leva à otimização de sistemas. As cidades inteligentes oferecem soluções tecnológicas para descrever o que acontece na cidade, como ela evolui e como é possível melhorar a qualidade de vida.

Considerando os sensores e sistemas de controle em tempo real e o grande volume de dados que podem ser gerados, Musa (2016) afirma que as cidades inteligentes podem abrir um leque de soluções tecnológicas e melhorar a qualidade de vida da população.

Portanto, utiliza-se esse conceito para a coleta de mais recursos (variáveis) para o desenvolvimento de previsões de consumo de energia e otimização dos gastos com energia. Conforme analisado no Tópico A, o uso de energia depende de inúmeros fatores. Assim, espera-se relacionar os dados de energia com temperatura e população flutuante, para encontrar correlações nos modelos de previsão.

D. Previsão de dados

No âmbito da Engenharia Elétrica, Amasyali & El-Gohary (2017) motivam o estudo da previsão do consumo de energia:

[...] é reconhecido que a realização de uma análise precisa do consumo de energia é uma tarefa formidável no estágio atual. Como uma alternativa, grandes esforços têm sido feitos para o desenvolvimento de modelos para prever e classificar o consumo de energia. [...] Os resultados simulados por esses modelos podem não só oferecer informações essenciais sobre a situação regional de edifícios, mas também facilitam estimativas de retornos e financeiros e ambientais sobre o investimento.

Segundo Amasyali & El-Gohary (2017), o resultado das simulações computacionais de previsões pode não somente oferecer informações relevantes sobre o uso de energia, mas como pode gerar benefícios econômicos e ambientais.

Com relação às dificuldades de implementação de algoritmos de previsão, o uso de energia elétrica em prédios leva em consideração diversos fatores, como condições climáticas, comportamento humano, ocupação dos edifícios, características do circuito elétrico, propósito de uso da construção, etc. A grande quantidade de variáveis de influência gera a um comportamento distinto e aleatório da curva de consumo.

No estudo sobre a abordagem orientada a dados, Zhao and Magoulès (2012), classificam diversos tipos de previsão de dados avaliados para o consumo de energia. Os autores definem três categorias para os modelos de previsão:

Atualmente, as abordagens empregadas para simulação de energia em prédios podem ser categorizadas como: (1) Baseada em White-box, (2) Baseada em Grey-box, (3) Baseada em Black-box.

Ainda de acordo com Zhao and Magoulès (2012), a categoria *White-box* tem como abordagem um modelo físico que necessita de informações sobre os fenômenos que ocorrem ao entorno do edifício.

Por sua vez, o modelo *Grey-box* é uma modificação do modelo *White-box*. Sua abordagem é a partir de métodos estatísticos combinados com uma versão simplificada dos fenômenos físicos com o histórico de consumo energético. Como característica geral, esse modelo envolve entradas de dados que são incertas com elementos estocásticos.

Por fim, a abordagem *Black-box* para análise do consumo de energia de um prédio se ampara apenas nos dados de consumo histórico, sem influências dos dados relacionados a fenômenos físicos. Conforme Zhao em Magoulès (2012), essa mudança “torna os modelos *black-box* de alta precisão e de rápido cálculo”, mas esses modelos dependem da qualidade dos dados e das técnicas de ajustes dos parâmetros.

Essas categorias de modelos de previsão são consideradas como métodos de aprendizado de máquina. Segundo Hosch (2020), editor da enciclopédia *Britannica*, a ciência de “aprendizado de máquina”, consiste em metodologias que dão aos computadores capacidade de aprender e serem mais precisos, sem a necessidade de serem explicitamente programados.

De acordo com a Google Inc. (2020), o aprendizado de máquina é possível na estruturação de algoritmos que são capazes de realizar verificações em seus resultados e tomar decisões previamente estabelecidas para otimizar os resultados futuros.

De forma geral, a capacidade de aprendizado de máquina está diretamente ligada à otimização dos resultados para o qual um algoritmo foi projetado. Espera-se que o método obtenha maior precisão à medida que novas informações descrevam o comportamento do objeto de estudo.

Wei, *et al.* (2017), em seu estudo, apresenta que algumas das abordagens orientadas à dados para realizar previsões são: Redes Neurais Artificiais (ANN), Máquina de Vetores de Suporte (SVM), Regressões Estatísticas e Clusterização. Modelos como ANN e SVM são considerados como *deep learning*, ou seja, algoritmos que tentam modelar abstrações de alto nível de dados usando uma estrutura profunda com várias camadas de processamento.

Em relação ao modelo de redes neurais artificiais, Zhao & Magoulès (2012) afirmam que seu uso é recomendado para resoluções de problemas não lineares. Por fim, o estudo desse modelo ao longo do tempo aborda a previsão de energia em diferentes tipos de consumo:

Nos últimos 20 anos, pesquisas que aplicaram as ANN para analisar vários tipos de consumo de energia em prédios, em uma variedade de condições, como como carga de aquecimento/ resfriamento, consumo elétrico, operação e otimização de componentes de sub-nível, estimativa de parâmetros de uso.

Segundo Zmeureanu and Runge (2019), as redes neurais podem ser empregadas para o processo de previsão quando devidamente treinadas e validadas. São modelos robustos e que contém, no mínimo, duas transformações não lineares.

Por sua vez, Deb *et al* (2017), apresentara em sua revisão sobre a previsão de energia que as redes neurais foram capazes de realizar previsões correlacionando dados históricos de energia, com temperatura, radiação solar e população. O resultado dessa modelagem trouxe precisão de R^2 de 0,81 e foi considerada superior ao modelo de regressão da curva de energia.

E. Redes Neurais Artificiais

Wei, *et al.* (2017) conceitua que as ANN são estruturadas inspiradas na arquitetura do cérebro humano. A rede consiste num grande número de unidades de processamentos, neurônios, organizadas em camadas. Uma camada se conecta a outra através das conexões entre neurônios.

Cada unidade de processamento lida com um sinal x_{il} ($i = 1, 2, \dots, m$) das unidades de processamento das camadas anteriores. Esses sinais entram para a próxima conexão associados com pesos x_{il} ($i = 1, 2, \dots, m$)

A Figura 1 ilustra o fluxo de processamento de uma unidade. Nela, é possível verificar que a saída sofre influência da função de ativação e do viés (*bias*). Em síntese, o cálculo passa por uma sumarização e é somado a uma constante b , que é responsável por ajustar e parametrizar o resultado para função de ativação. Por sua vez, a função de ativação, como exemplo da função sigmoide (curva logística), possui como objetivo normalizar o resultado da sumarização com valores entre 0 (não ativado) e 1 (ativado) e introduzir uma componente de não linearidade. As equações 1 e 2 se referem as funções de sumarização e de ativação de um neurônio, respectivamente.




Figura 1 - Esquema interno de um neurônio

$$y_i = \sum_{i=1}^n (w_i x_i) + b_i \quad (1)$$

$$f(x) = \frac{1}{1 + e^x} \quad (2)$$

O resultado desse cálculo é utilizado como entrada para a unidade de processamento da próxima camada, conectada ao neurônio anterior.

Ainda sobre as ANN, Wei, *et al.* (2017) afirma que, “independentemente da arquitetura utilizada, as redes precisam ser treinadas para o ajuste os pesos e dos vieses, antes de serem utilizadas de forma efetiva”. Esse processo de treinamento aproveita os dados históricos das variáveis de entrada e realiza cálculos iterativos para a devida modelagem.

A abordagem desse trabalho se reserva em prever o consumo energia a curto prazo, para garantir informações relevantes no momento da avaliação de conformidade da unidade consumidora. Diante do exposto, torna-se um problema de regressão. Dadas variáveis de entrada X, espera-se obter uma variável Y como saída. Além disso, o objetivo desse trabalho é elaborar um método de validação e gestão do consumo, de fácil empregabilidade e reprodutibilidade.

Silva (2017) aborda sobre as arquiteturas de redes neurais artificiais. Sobre a rede *Multilayer Perceptron* (MLP), o autor discorre que seu potencial de aplicação em problemas de regressão (aproximação de curvas) é para previsão de séries temporais e conhecimento de parâmetros. Dentre suas aplicações, a MLP é utilizada em medicina, biologia, economia e física.

Ainda, esse modelo é classificado como *feedforward* e sua forma de treinamento é supervisionada, com algoritmo chamado de

backpropagation. A Figura 2 representa um esquema genérico de uma rede MLP. Verifica-se que o fluxo de propagação segue apenas uma direção na rede, o que geram as camadas de *input* e *output*.

Segundo Silva (2017), o algoritmo busca minimizar a função de erro para se ajustar a curva dos dados. Cada neurônio distribui o conhecimento para toda a rede e as camadas intermediárias, por sua vez, extraem a maior parte das informações relacionadas com o sistema e codifica utilizando os pesos de cada sinapse.




Figura 2 - Esquema genérico de uma rede MLP (Fonte: Silva, 2017)

III. BASE DE DADOS

A base de dados a ser estudada refere-se aos dados públicos de consumo de energia de prédios (MÖBIUS, 2021), disponibilizados na plataforma Kaggle. O objetivo da publicação é justamente incentivar o estudo de previsões de dados. Os dados estão organizados por tabelas relacionadas e possuem identificadores para realizar junções.

Inicialmente, a tabela de consumo de energia relaciona um determinado instante de medição com seu respectivo valor de consumo e com um determinado prédio. Assume-se que a unidade da medição de energia informada é *kWh*.

Com relação a base de temperatura, associa-se uma determinada medição de temperatura em um instante a um prédio. Assume-se, que a unidade de temperatura é Grau Celsius (°C), considerando que os valores da base de dados se limitam à escala dessa unidade. Ainda, na base, existe um campo para a distância em quilômetros entre o ponto de medição de temperatura e o prédio, naquele instante.

Ainda, são fornecidos dados de feriados locais de cada prédio, para correlacionar um menor gasto energético com uma queda da atividade laboral. Pela base, não é possível obter características físicas dos edifícios ou verificar aspectos de geolocalização.

Com relação à quantidade de dados e medições, a Figura 3 retrata a quantidade de registros de energia por identificador de prédio (*SiteId*). Nela, é possível identificar que alguns edifícios carecem de informações, enquanto outros apresentam uma grande quantidade de registros. O intervalo temporal entre os registros da base de dados é variado, de acordo com cada prédio.




Figura 3 – Quantidade de registros por identificador de prédio (Fonte: O autor)

Conforme Möbius (2021), nem todos os prédios possuem medições de temperatura para os instantes que foram coletadas as informações de energia. Assim, devem ser realizadas as devidas tratativas para a escolha do prédio a ser previsto, considerando que a variáveis de entrada possuam conformidade.

IV. METODOLOGIA

Para a implementação da metodologia de aprendizado e máquina para previsão de dados, inicialmente foi necessário o pré-processamento das informações disponíveis e preparação para treino na rede neural.

A. Pré-processamento

Realizou-se o pré-processamento dos dados em linguagem de programação *Python*. Conforme abordado por McKinney (2019), “a biblioteca *pandas* contém estruturas de dados e ferramentas para manipulação de dados, projetadas para agilizar e facilitar a limpeza e a análise de dados em *Python*”. A base dessa etapa foi a junção das tabelas e escolha dos recursos para previsão. Por sua vez, a biblioteca *matplotlib* foi utilizada para visualização dos dados a partir do traçado de gráficos. Essa biblioteca é citada por McKinney (2019) como um pacote de renderização gráfica para desktop, projetada para criar gráficos com qualidade para publicação. Nesse sentido, o autor ainda afirmar que os gráficos são parte do processo exploratório dos dados.

Inicialmente, foram estudadas cada base de dados separadamente, antes do relacionamento. Verifica-se que existem mais de uma medição de temperatura para o mesmo identificador de prédio, no mesmo instante de tempo, porém, para distâncias diferentes. Nesse sentido, considerou-se como uma informação que melhor descreve a temperatura periférica do prédio como o valor da menor distância entre o ponto de medição e o edifício em questão.

Em segundo momento, foi desenvolvida uma normalização da coluna de tempo para ser possível realizar a inserção na rede neural. Para isso, foi necessário transformar os dados de hora do dia em valores entre -1 e 1. Considerando que o consumo de energia do final do dia (23:59) e início do dia seguinte (00:00) é próximo, torna-se importante que o valor numérico possua uma proximidade e permita caracterizar de maneira mais concisa o comportamento da curva de consumo.

Para essa normalização, o artigo de Kaleko (2017) foi utilizado com base teórica. Segundo o autor, o dado de hora pode ser considerado como crítico e se torna necessária a modelagem de forma senoidal periódica. Para adequação aos algoritmos de aprendizado de máquina,

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

o autor sugere a criação de um vetor que normaliza o valor da hora no instante da informação. Ele afirma que:

Utilizando esse recurso de engenharia para sistemas cíclicos definitivamente ajuda. O modelo obteve mais facilidade para interpretar os recursos projetados. O que é interesse dessa metodologia e que ela não só melhora a performance, mas também realiza isso de uma forma que é lógica para a compreensão humana.

Assim, esse recurso matemático permite que o algoritmo consiga realizar as interpretações que para o ser humano são lógicas, mas que para a máquina não são apresentadas com clareza nos primeiros treinos. A implementação do código em Python para a base de dados estudada é realizada de acordo com as equações 3 e 4. São necessárias duas colunas para descrever as horas do dia. Diferente da metodologia de Kaleko (2017), utilizou-se também a informação dos minutos, aumentando a resolução disponível das colunas de tempo.

$$df[hr_sin] = \sin\left(\left(hora + \frac{min}{60}\right) \cdot \frac{2\pi}{24}\right) \quad (3)$$

$$df[hr_cos] = \cos\left(\left(hora + \frac{min}{60}\right) \cdot \frac{2\pi}{24}\right) \quad (4)$$

A Figura 4 se refere ao comportamento das colunas de tempo entre um dia. É possível identificar que o comportamento foi modelado de forma a identificar horas antes e depois do meio dia, a partir dos quadrantes do círculo trigonométrico.




Figura 4 – Normalização do tempo em um dia

Ainda, foi necessário realizar as junções entre as bases de dados para definir os edifícios a serem estudados. O comando *merge* foi utilizado para esse procedimento. Em seguida, foram exportados os dados para escolha do prédio a ser previsto.

Para a escolha do edifício de previsão, foram analisadas a quantidade de registros de energia e a proporção de registros de temperatura. O prédio com identificador 40 foi escolhido para esse estudo. Após consolidação dos dados, verifica-se que o edifício escolhido possui o primeiro registro em 03 de julho de 2015 às 14:30:00 e última medição em 08 de novembro de 2017 às 13:30:00. A proporção de registros de temperatura para o mesmo instante de tempo de registros de energia é de 99% da base. A quantidade total de medições é de 17.352 linhas.

Com relação a frequência de medição, 17.335 das medições

possuem intervalo de 1h da medida anterior, enquanto há 17 registros com intervalos de 193h. Isso justifica o comportamento dos gaps das Figuras 5 e 6. Tais gaps não foram descartados dos conjuntos de treino e de teste, uma vez que a separação empregada da base de dados foi aleatória.




Figura 5 – Medições de energia SiteId = 40




Figura 6 – Medições de temperatura SiteId = 40

Para melhor visualização dos dados, as Figuras 7 e 8 amostram o comportamento de energia e temperatura no dia 20 de setembro de 2016, respectivamente.




Figura 7 – Medições de energia em um dia SiteId = 40




Figura 8 – Medições de temperatura em um dia SiteId = 40

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

Uma característica desse prédio foi que ele apresentou picos medições de energia no período noturno. Como esse foi um comportamento que se propaga por toda a base de dados, considerou-se esse fator como um aspecto inerente do edifício. Ainda, como a localização apresenta temperaturas negativas, o gasto energético no período noturno se justifica por aquecedores.

Por fim, a Figura 9 apresenta um gráfico de correlação de Pearson das 17.352 observações entre as variáveis energia, temperatura e a hora do dia, considerando as colunas da transformação proposta por Kaleko (2017). Observa-se uma correlação negativa entre temperatura e o uso de energia, que pode indicar maiores gastos com sistemas de aquecimento. Ademais, os dados de temperatura se correlacionam minimamente com a informação temporal, evidenciando o ciclo diurno do clima. Com o uso de um método de previsão não linear e por meios desses recursos, espera-se destacar uma metodologia para previsão da variável de interesse, o consumo energético.




Figura 9 – Correlação de Pearson entre as variáveis. *Siteld* = 40

B. Implementação da MLP

De acordo com Pedregosa (2011), na publicação do *Scikit-learn*, “aprender os parâmetros de previsão e os testar no mesmo conjunto de dados é metodologicamente um erro”. O modelo que extrai as características de um determinado conjunto de dados e realiza o teste nesse mesmo conjunto obterá uma alta performance, mas falhará para generalizar essas previsões para dados ainda não descobertos. Essa situação é chamada de sobreajuste (*overfitting*).

O sobreajuste está diretamente ligado ao método de treino do modelo de previsão. A possibilidade do resultado ser enviesado pelos dados ocorre quando o conjunto de dados de treino é o mesmo conjunto de dados para realizar os testes. Assim, o modelo memoriza os dados do treino em vez de aprender com eles, para replicar o método em outro conjunto. O potencial de sobreajuste depende não só do número de parâmetros do modelo, mas também da conformidade do modelo com a estrutura dos dados.

Ainda segundo Pedregosa (2011), para evitar tal comportamento na performance de algoritmos supervisionados, ou seja, que possuem os dados de referência para verificação do erro de previsão, utiliza-se técnicas denominadas de Validação Cruzada, na qual se particiona a massa de dados em treino e teste.

O método *k-fold*, já foi abordado para previsão de energia no estudo de Tabrizchi, Javidi, & Amirzadeh (2019). Nele, os autores concluem

que o uso do método teve um resultado satisfatório para a previsão de energia de edifícios.

Segundo Tabrizchi, Javidi, & Amirzadeh (2019), na validação cruzada de *k-fold*, a massa de dados é particionada em *k* grupos de tamanhos iguais. Cada um dos *k* grupos são utilizados para medir a acurácia do método de previsão e os outros *k-1* grupos são utilizados para construir o modelo.

O erro resultante de cada grupo *k*, em geral, é utilizado para calcular a média do erro final. Nesse sentido, uma das vantagens da validação cruzada é que todos os dados utilizados no processo, seja treino e teste, podem ser computados *k* vezes. Portanto, o erro quando se utiliza a validação cruzada tem menor variância quando se comparado ao grupo apenas de treino e de teste.

Para o particionamento aleatório dos dados e realizar treinos com diversas combinações de parâmetros, realiza-se a implementação da rede neural por meio da biblioteca *scikit-learn*, que é um código aberto para linguagem de programação Python relacionada ao aprendizado de máquina.

A partir da biblioteca, realizou-se a implementação da Rede Neural Multilayer Perceptron (*MLPRegressor*) aliada ao recurso *Pipeline* e *GridSearchCV*. O recurso *Pipeline* elabora uma série de procedimentos para o computador processar os dados, de forma que sua implementação seja simples. Por sua vez, o *GridSearchCV* é capaz de particionar a base em “*k*” compartimentos e realizar a combinação de treinos com os diversos parâmetros selecionados. Os treinos desse estudo consideram 10 compartimentos para a validação cruzada, a partir da separação aleatória de 75% da base para conjunto exclusivo de treino. Os demais 25% foram utilizados exclusivamente para testar o melhor modelo encontrado na etapa anterior.

Ademais, para a escolha do melhor resultado de treinamento, utilizou-se a média de pontuação entre os “*k*” compartimentos da validação cruzada.

Em síntese, o treino e ajuste de algoritmos de aprendizado de máquina partem de uma premissa experimental. A Figura 10, da própria documentação do *Scikit-learn* aborda uma metodologia para determinação dos melhores parâmetros de um algoritmo, tanto em âmbito acadêmico quando em âmbito comercial.




Figura 10 – Fluxo de treinamento típico de uma validação cruzada, Pedregosa (2011)

Assim, a metodologia dessa pesquisa busca, inicialmente, evidenciar os parâmetros que melhor se ajustaram ao conjunto de dados e, em seguida, buscar soluções para otimizar o desempenho da metodologia de previsão

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

Timestamp	Energia	Temperatura	Marcação Feriado	Hora	Minuto	Tempo	Hora Seno	Hora Cosseno	Energia Anterior	Temperatura Anterior
2015-07-03 14:30:00+00:00	6997.984367	31.0	0.0	14	30	14.5	-0.608761	-0.793353	0.000000	0.0
2015-07-03 15:30:00+00:00	15518.012898	33.0	0.0	15	30	15.5	-0.793353	-0.608761	6997.984367	31.0
2015-07-03 16:30:00+00:00	6674.491991	34.0	0.0	16	30	16.5	-0.923880	-0.382683	15518.012898	33.0
2015-07-03 17:30:00+00:00	4920.282616	33.0	0.0	17	30	17.5	-0.991445	-0.130526	6674.491991	34.0
2015-07-03 18:30:00+00:00	4118.787012	34.0	0.0	18	30	18.5	-0.991445	0.130526	4920.282616	33.0

Figura 11 – Estrutura da Base de Dados

Os parâmetros da rede neural fixos foram uma taxa de aprendizado constante, com a função de ativação sendo a tangente hiperbólica e o método de aprendizagem *adam*, que são os padrões da implementação da rede. Foi utilizada apenas uma camada oculta com a variação da quantidade de neurônios. Pelo *Pipeline*, realizou-se a normalização dos dados entre -1 e 1, a partir da função *MinMaxScaler*.

Com relação à métrica de precisão, foi considerado o coeficiente de determinação (R^2) médio entre os compartimentos. Segundo Pedregosa (2011), esse coeficiente promove um entendimento de quão bom o modelo é capaz de se ajustar à curva e como o algoritmo é capaz em prever dados não reconhecidos. Sua fórmula é apresentada na equação 5, onde $\bar{y}$ é a média dos valores verdadeiros e $\hat{y}_i$ os valores previstos na amostra i . Nesse sentido, quanto maior de 1, melhor é o ajuste do modelo às características dos dados.

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5)$$

Inicialmente, variou-se a quantidade de neurônios ocultos entre 10, 30 e 50 e a quantidade de iterações em 1500, 3500 e 5000. Também foram variados os recursos de entrada da rede neural, em busca de simplificar as análises e a capacidade de encontrar comportamentos significativos dos dados.

Por fim, a Figura 11 apresenta a estrutura do conjunto de dados após o pré-processamento e as disponibilidades de recursos para previsão, considerando que a coluna de consumo de energia (*Value*) é a variável a ser prevista.

I. RESULTADOS

A metodologia empregada apresentou resultados a partir da métrica de desempenho médio entre os compartimentos da validação cruzada de cada algoritmo. Os parâmetros fixos dos treinos ficaram sendo a função de ativação como tangente hiperbólica, o método de aprendizagem *adam* e apenas uma camada oculta. Variou-se os recursos de entrada na rede neural, a quantidade de neurônios ocultos e o número de iterações. A Tabela 1 apresenta as variações dos parâmetros de entrada na rede neural.

TABELA I
RECURSOS DE TREINO PARA ENTRADA DA MLP

Índice	Recursos de Entrada
1	Temperatura Atual, Hora Seno, Hora Cosseno
2	Temperatura Anterior, Energia Anterior, Hora Seno, Hora Cosseno
3	Temperatura Anterior, Energia Anterior, Hora
4	Temperatura Atual, Energia Anterior, Hora Seno, Hora Cosseno
5	Temperatura Atual, Temperatura Anterior, Energia Anterior, Hora
6	Temperatura Atual, Temperatura Anterior, Energia Anterior, Hora Seno, Hora Cosseno
7	Temperatura Atual, Temperatura Anterior, Energia Anterior, Hora Seno, Hora Cosseno, Marcação de Feriado

Por sua vez, a Tabela 2 apresenta o melhor resultado dos treinos de cada combinação de entrada e seus respectivos parâmetros selecionados. A Tabela está ordenada pela maior pontuação de previsão.

Verifica-se que o número de iterações não influenciou significativamente a precisão dos algoritmos e, em alguns casos, a pontuação média entre os conjuntos da validação cruzada foi igual. Assim, os valores com menor iterações foram considerados melhores, visto que diminuiriam a parametrização do algoritmo.

Ainda, foi possível observar que alguns dos treinos obtiveram resultado negativo para o R^2 . Segundo a equação 5, isso é possível quando a razão entre os somatórios resulta em um valor maior que 1. Para isso, o erro de previsão é consideravelmente grande em relação ao valor real. Assim, é possível evidenciar que os treinos com esses resultados não foram capazes de realizar um ajuste na curva dos dados a serem previstos e foram descartados da comparação.

TABELA 2
RECURSOS DE TREINO PARA ENTRADA DA MLP

Número de Neurônios	Iteração Máxima (Número de épocas)	Índice Recursos de Entrada	Métrica de Desempenho (R^2)
50	1500	7	0,86942
30	1500	1	0,26030
50	1500	2	0,08629
50	1500	4	0,08593
30	1500	6	0,08466
50	3500	3	0,08394
30	3500	5	0,08363

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

Segundo a Tabela 2, o melhor modelo obtido, referência os recursos de índice 7 da Tabela 1, que considerou o máximo de colunas disponíveis para previsão. O modelo foi capaz de prever em ambiente de treino com um $R^2 = 0,86942$. Em comparação com os demais treinos, houve uma grande diferença no resultado. Parte disso pode ser explicado pela modelagem do tempo como duas colunas e a possibilidade de diferenciar os períodos da manhã e noite. Ademais, a inserção da marcação de feriado justifica a redução de consumo para determinados dias e pode ter influenciado positivamente na aprendizagem do modelo.

Com relação os dados de energia e temperatura, verifica-se que os registros dos períodos anteriores levam a grandes correlações para as previsões. Isso também pode ser analisado a partir da diferença de pontuação entre os treinos com entradas diferentes. Nesse sentido, a própria variável energia e temperatura tiverem influência sobre o valor a ser previsto. Esse comportamento era esperado, principalmente pela proximidade entre as medições da base de dados (intervalos de 1h).

Considerando que os melhores recursos de entrada foram: Temperatura Atual, Temperatura Anterior, Energia Anterior, Hora Seno, Hora Cosseno e Marcação de Feriado, foi possível realizar um retreino da base, agora alterando apenas a quantidade de neurônios ocultos da única camada.

A Figura 12 mostra o comportamento da pontuação de previsão para a quantidade de neurônios ocultos. Evidencia-se que até 10 neurônios, a rede neural não foi capaz de se ajustar aos dados e realizar minimamente alguma previsão. A partir do 11º neurônio é possível evidenciar uma melhora na forma que o algoritmo aprendeu com o conjunto de dados.

O melhor resultado dessa previsão foi para 43 neurônios ocultos, com valor de R^2 médio entre as os subconjuntos de 0,86419. Foi possível também observar que, com os dados de treino, a taxa de aprendizado não aumenta de forma proporcional à quantidade de neurônios e que inclusive ele pode decair com o acréscimo de cada unidade. Ademais, incrementar o número de neurônios pode aumentar a parametrização do algoritmo e ainda gerar sobre ajuste dos dados.




Figura 12 – Pontuação por quantidade de neurônios ocultos

Considerando os resultados da variação de neurônios nos recursos de entrada que obtiveram a melhor performance (Índice 7), utilizou-se 43 neurônios para realizar a previsão no conjunto de teste, sendo os 25% restantes da base.

Após o retreino da base e aplicação da rede em um conjunto totalmente desconhecido, foi possível obter um R^2 de 0,86773. Sobre o teste da rede neural, a Figura 13 apresenta o gráfico de dispersão da variável real em relação à variável prevista. Identifica-se uma correlação positiva visualmente pelos gráficos e é possível verificar as amostras que foram responsáveis pela redução de precisão. O valor do coeficiente de correlação entre as variáveis foi de 0,93177, e se aproxima da referência da unidade.




Figura 13 – Pontuação por quantidade de neurônios ocultos

Já na Figura 14 está apresentado o histograma dos resíduos das previsões com a base de teste. A curva em questão considera compartimentos iguais de 100 (kW, considerando a unidade de medida de energia). Verifica-se um comportamento gaussiano na distribuição. Para que o modelo tenha um desempenho de generalização eficiente, é necessário que as colunas do histograma estejam simétricas, com média centrada em zero e desvio padrão unitário. Nesse sentido, o resultado encontrado indica um modelo que conseguiu extrair informações importantes do conjunto de dados e foi capaz generalizar as previsões.




Figura 14 – Histograma dos resíduos de previsão.

A partir dos resultados apresentados, observa-se que o teste do modelo com a base desconhecida dos treinos ficou em linha com a precisão esperada, sendo essa acima de 80%. O modelo teve bom desempenho quando se considera os valores anteriores da variável energia e uma boa correlação entre os testes e os valores reais.

A aprendizagem de máquina se demonstra como uma solução promissora para gestores analisarem os consumos. O modelo de previsão ajustado a curva de consumo de um edifício pode ser utilizado como fator auxiliar para a gestão de consumo e, consequentemente, indicar as medições que destoam do modelo do prédio. Todavia, a precisão do modelo em questão se aplica a intervalos de medições intradia e dependem da medição anterior. Assim, deve-se utilizar a atual modelagem para verificação exclusiva de curto prazo.

Centro Federal de Educação Tecnológica de Minas Gerais – CEFET-MG

II. CONCLUSÕES

A partir desse estudo, foi possível evidenciar como funciona o processo de liquidação de despesas públicas e a análise do consumo energético. Uma gestão mais eficiente, baseada em dados, pode gerar em economia financeira e ser utilizada como sinalizador para problemas das unidades consumidoras.

Nesse sentido, com relação ao consumo energético de prédios públicos, identifica-se que grande parte do consumo está associado aos equipamentos de refrigeração e sistemas de iluminação. Assim, fatores externos como clima e atividade laboral podem descrever o comportamento do consumo energético desses edifícios. O registro estruturado permite a análise do consumo de energia e auxilia na tomada no julgamento do uso do recurso natural.

Foi realizada a previsão de energia de uma base de dados pública que considera o edifício como uma unidade consumidora. A partir dessa pesquisa, modelou-se o sistema por uma rede neural Multilayer Perceptron (MLP).

A metodologia inicial considerou parâmetros padrões do algoritmo e a variação dos recursos de entrada, quantidade de neurônios e quantidade de iterações. Observa-se que em ambiente de treino, para o edifício escolhido em questão, o pré-processamento dos dados e a modelagem do tempo como duas colunas periódicas trouxe maior precisão ao modelo.

Ademais, a quantidade de iterações da rede não trouxe ganho de performance para o modelo, enquanto aumentar a quantidade de neurônios não tem influência direta na sua eficiência.

Com relação ao teste da rede neural, evidencia-se que o algoritmo foi capaz de generalizar as informações e realizar previsões com os dados desconhecidos. A correlação entre os dados reais e os dados previstos ficou próxima de 1, enquanto o histograma de resíduos mostrou um comportamento gaussiano centrado em zero e de forma simétrica.

Considerando os objetivos de trabalho, a precisão da metodologia foi considerada satisfatória. Verifica-se que algoritmos de aprendizado de máquina podem ser utilizados para previsão de curto prazo de consumo de energia em prédios públicos e servir como balizador para a gestão de faturas. Todavia, torna-se necessário realizar o estudo com intervalos mensais da série, para correlacionar corretamente com os períodos de faturamento.

Como trabalhos futuros, sugere-se realizar testes com mais de uma camada oculta e variar o método de aprendizagem, em busca de otimizar a precisão do algoritmo. Ainda, é possível variar a arquitetura da rede para outros modelos de regressão como *RandomForest*.

REFERÊNCIAS

- [1] ABESCO, Associação Brasileira das Empresas de Serviços de Conservação de Energia. **O que é Eficiência Energética? (EE)**. Disponível em: <<http://www.abesco.com.br/pt/o-que-e-eficiencia-energetica-ee/#:~:text=Efici%C3%Aancia%20energ%C3%A9tica%20%C3%A9%20uma%20atividade,se%20obter%20um%20determinado%20resultado>>. Acesso em 27 de dezembro de 2020.
- [2] AMASYALI, K., & EL-GOHARY, N. M. A review of data-driven building energy consumption prediction studies. **Renewable and Sustainable Energy Reviews**, p. 1192–1205, 2017.
- [3] ANEEL, Agência Nacional De Energia Elétrica. (03 de abril de 2012). **RESOLUÇÃO NORMATIVA N° 479, DE 3 DE ABRIL DE 2012**. Disponível em: <<https://www.aneel.gov.br/documents/656877/14486448/ren2012479.pdf/a89312fe-a5d7-4151-96be-95765ea2ce03?version=1.0>>. Acesso em 25 de maio de 2021.
- [4] COSTA, A. F. **Fiscal de contratos administrativos: atribuições**. Disponível em: <<https://jus.com.br/artigos/24855/aspectos-gerais-sobre-o-fiscal-de-contratos-publicos/2#:~:text=LIQUIDA%C3%87%C3%83O%20DA%20DESPESA&text=%E2%80%9CA%20liquida%C3%A7%C3%A3o%20da%20despesa%20consiste,umpriu%20o%20que%20foi%20pactuado>>. Acesso 03 de novembro de 2020.
- [5] D'ALBUQUERQUE, M. A., SILVA, R. M., & Gomes, M. B. Eficiência Energética Em Uma Edificação Pública. **Sistemas & Gestão**, p. 462–470, 2017.
- [6] DEB C. *et al.* **A review on time series forecasting techniques for building energy Consumption**. Renewable and Sustainable Energy Reviews, p.9-12, 2017.
- [7] GONÇALVES, A. C. **Eficientização Energética Em Prédios Públicos: Um Desafio Aos Gestores Municipais Frente Aos Requisitos De Governança E Sustentabilidade**, São Paulo, p. 1-25, 2012.
- [8] GOOGLE INC. **Machine Learning Crash Course**. Developers Google. Disponível em: <<https://developers.google.com/machine-learning/crash-course/training-and-test-sets>>. Acesso em 12 de outubro de 2020.
- [9] HOSCH, W. L. **Machine learning**. Encyclopædia Britannica. Disponível em: <<https://www.britannica.com/technology/machine-learning>>. Acesso em 24 de fevereiro de 2021.
- [10] INEE, Instituto Nacional de Eficiência Energética. **O que é Eficiência Energética**. Disponível em: <http://www.inee.org.br/eficiencia_o_que_eh.asp?Cat=eficiencia>. Acesso em 03 de novembro de 2020.
- [11] KALEKO, D. **Feature Engineering - Handling Cyclical Features**. Disponível em: <<http://blog.davidkaleko.com/feature-engineering-cyclical-features.html>>. Acesso em 13 de junho de 2021.
- [12] MCKINNEY, W. **Python Para Análise de Dados**. Tratamento de dados com Pandas, Numpy e iPython. Primeira Edição, 2019. São Paulo: Novatec Editora.
- [13] MÖBIUS. **Building Sites Power Consumption**. Forecast energy consumption in different time steps and granularities. Disponível em: <<https://www.kaggle.com/arashnic/building-sites-power-consumption-dataset>>. Acesso em 12 junho 2021.
- [14] MUSA, Sam. **Smart City Roadmap**. Academia. Disponível em: <https://www.academia.edu/21181336/Smart_City_Roadmap>. Acesso em 25 de maio de 2021.
- [15] PEDREGOSA *et al.*, **Scikit-learn: Machine Learning in Python**, JMLR 12, pp. 2825-2830, 2011.
- [16] PROCEL, Programa Nacional de Conservação de Energia Elétrica. **Edificações**. Disponível em: <<http://www.procelinfo.com.br/main.asp?TeamID=%7B82BBD82C-FB89-48CA-98A9-620D5F9DBD04%7D#:~:text=O%20Procel%20promove%20a%20avalia%C3%A7%C3%A3o,edifica%C3%A7%C3%B5es%2C%20a%20Etiqueta%20PBE%20Edifica>>. Acesso em 15 de outubro de 2020.
- [17] SILVA, I. N., SPATTI, DANIELO H., FLAUZINO, ROGERIO A., LIBONI, LUISA H. B., ALVES, SILAS F. R. **Artificial Neural Networks**. A Practical Course. Primeira Edição, 2017. São Carlos: Springer.
- [18] TABRIZCHI, H., JAVIDI, M. M., & AMIRZADEH, V. **Estimates of residential building energy consumption using**. Evolving Systems, 2019.
- [19] WEI, Y. *et al.* **A review of data-driven approaches for prediction and classification of**. Renewable and Sustainable Energy Reviews, p. 1-21, 2017.
- [20] ZHAO, H., & MAGOULÈS, F. **A review on the prediction of building energy consumption**. Renewable and Sustainable Energy Reviews, pp. 1-7, 2012.
- [21] ZMEUREANU, J. and RUNGE R. **Forecasting Energy Use in Buildings Using Artificial Neural Networks: A Review**. Energies, p. 5-8, 2019.