

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Ciência de Dados e Big Data

Evandro Ribeiro Gomes Coelho

**Previsão do Consumo Energético de Edifícios com Modelos de Aprendizado de
Máquina: Um Estudo Comparativo com Engenharia de Recursos Expandida**

Belo Horizonte

2026

Evandro Ribeiro Gomes Coelho

**Previsão do Consumo Energético de Edifícios com Modelos de Aprendizado de
Máquina: Um Estudo Comparativo com Engenharia de Recursos Expandida**

Trabalho de Conclusão de Curso apresentado ao
Curso de Especialização em Ciência de Dados e Big
Data como requisito parcial à obtenção do título de
especialista.

Belo Horizonte

2026

SUMÁRIO

1. Introdução	5
1.1. Contextualização.....	5
1.2. O problema proposto.....	6
1.3. Objetivos.....	7
2. Coleta de Dados	8
3. Processamento/Tratamento de Dados	9
3.1 Junção entre as bases de dados.....	10
3.2 Identificação de valores ausentes e gaps temporais	10
3.3 Identificação de outliers	11
3.4 Engenharia de recursos.....	11
4. Análise e Exploração dos Dados.....	15
5. Criação de Modelos de Machine Learning.....	18
5.1 Modelos de referência	18
5.2 Modelos avançados	19
6. Interpretação dos Resultados	24
7. Apresentação dos Resultados	28
8. Links	32
REFERÊNCIAS.....	33
APÊNDICE	35

1. Introdução

No âmbito do consumo energético em prédios, a previsão de curto prazo orienta a gestão de faturas e pode sinalizar consumos ineficientes. Trabalhos anteriores do autor (COELHO, 2021a; COELHO, 2021b) demonstraram a viabilidade de redes neurais do tipo *Multilayer Perceptron* (MLP) para essa finalidade, alcançando R^2 de 0,868 com seis recursos de entrada. O presente estudo propõe uma evolução metodológica fundamentada em engenharia de recursos expandida — de seis para vinte variáveis preditoras — e na comparação sistemática entre quatro algoritmos de aprendizado de máquina: MLP, *Random Forest*, *XGBoost* e *Long Short-Term Memory* (LSTM). A base de dados utilizada é a *Building Sites Power Consumption* (MÖBIUS, 2021), disponível na plataforma *Kaggle*, com foco no edifício de identificador 40, que registra 17.352 medições horárias no período de julho de 2015 a novembro de 2017. A metodologia inclui análise exploratória, engenharia de recursos com variáveis de atraso, médias móveis e codificação cíclica, além de validação cruzada temporal com cinco partições.

Palavras-chave: Previsão de consumo energético de curto prazo. Aprendizado de máquina. Engenharia de recursos. Redes neurais artificiais. Edifícios.

1.1. Contextualização

O uso da energia está presente de forma intensiva na maior parte das atividades humanas. Dentre as diversas formas de energia, as que são processadas pela sociedade e colocadas à disposição de consumidores abrem um grande leque de estudos, seja na forma de gás natural, combustível, eletricidade, entre outras. Com o uso extensivo desse recurso, passou também a se tornar preocupação e objeto de estudo o seu emprego eficiente.

No âmbito da eficiência energética em edificações, a Associação Brasileira das Empresas de Serviço e Conservação de Energia (ABESCO, 2020) a define como "a utilização racional de energia, que consiste em usar de modo eficiente a energia para se obter um determinado resultado". Assim, a eficiência está diretamente associada ao comportamento dos dispositivos e às práticas de gestão dos ambientes, visto que o desperdício por uso inadequado representa parcela significativa do consumo total. No que se refere à finalidade do uso de energia, segundo o Programa Nacional de Conservação de Energia Elétrica (PROCEL, 2020),

"cerca de 70% do consumo de energia se deve ao uso dos sistemas de iluminação e climatização" em edificações, o que confirma a relevância de monitorar e prever o comportamento desses sistemas ao longo do tempo para se garantir o uso com eficiência.

Nesse sentido, a previsão do consumo energético emerge como ferramenta estratégica de gestão. No âmbito da Engenharia Elétrica, Amasyali & El-Gohary (2017) motivam o estudo da previsão do consumo de energia ao afirmar que os modelos computacionais "podem não só oferecer informações essenciais sobre a situação regional de edifícios, mas também facilitam estimativas de retornos financeiros e ambientais sobre o investimento". Dessa forma, a combinação de registro de dados estruturados e algoritmos de previsão, como o aprendizado de máquina, tornam-se uma ferramenta útil para lidar com decisões de gestão operacional e manutenção.

Em trabalhos anteriores, estudou-se essa problemática no contexto de prédios públicos do Tribunal Regional do Trabalho da 3ª Região (TRT3), em Minas Gerais. Em um primeiro momento, foi realizado um levantamento bibliográfico e estruturada a base de dados de consumo energético das unidades do TRT3, identificando-se os desafios relacionados à quantidade de registros disponíveis para implementação de modelos de aprendizado de máquina (COELHO, 2021a). Em um segundo trabalho, foi implementada uma rede neural artificial do tipo *Multilayer Perceptron* (MLP) para previsão de curto prazo, utilizando dados da plataforma *Kaggle*. O modelo obteve R^2 de 0,86773 no conjunto de teste, empregando seis recursos de entrada e validação cruzada *k-fold* com particionamento aleatório (COELHO, 2021b).

O presente trabalho representa a evolução natural desses estudos no contexto do curso de pós-graduação. Propõe-se uma investigação mais aprofundada, com a ampliação do conjunto de recursos preditores, a introdução de modelos de referência e a comparação entre quatro algoritmos de aprendizado de máquina, avaliados sobre o mesmo conjunto de dados e com metodologia de validação temporal mais rigorosa.

1.2. O problema proposto

A previsão do consumo energético de edifícios é um problema de regressão em séries temporais. Dadas variáveis de entrada X , espera-se obter a variável de consumo energético Y

como saída, no horizonte temporal à frente. Esse trabalho busca a previsão de curtíssimo prazo, dada que as amostragens possuem gradualidade de 1 hora, mas a motivação do estudo está na análise e controle das despesas de energia elétrica, que por sua vez, são mensais. Apesar da diferença temporal das observações, o estudo motiva o uso de sensores para melhor coleta de dados sobre as instalações elétricas e viabiliza a ideia de ser prever o consumo com base em dados históricos.

No âmbito financeiro, a correta gestão das despesas de energia em edifícios pode evitar gastos com inadimplência, identificar ineficiências e orientar manutenções preventivas. Conforme exposto em COELHO (2021b), "a aprendizagem de máquina se demonstra como uma solução promissora para gestores analisarem os consumos. O modelo de previsão ajustado à curva de consumo de um edifício pode ser utilizado como fator auxiliar para a gestão de consumo e, conseqüentemente, indicar as medições que destoam do modelo do prédio."

Nesse sentido, o problema central que essa pesquisa se propõe a investigar é em que medida a expansão do conjunto de recursos preditores e a adoção de múltiplos algoritmos de aprendizado de máquina melhoram a capacidade de previsão do consumo energético de um edifício em comparação com a abordagem de rede neural simples com poucos recursos, aplicada nos trabalhos anteriores. Além disso, esse trabalho investiga a técnica de validação cruzada do primeiro estudo e apresenta um modelo que não permite vazamento de dados na etapa de treino.

1.3. Objetivos

O objetivo geral desse estudo é desenvolver e comparar modelos de aprendizado de máquina para previsão de curto prazo do consumo energético de edifícios, com ênfase na contribuição da engenharia de recursos para o desempenho preditivo.

Os objetivos específicos são:

- Realizar a análise exploratória dos dados de consumo e temperatura do edifício de referência, identificando padrões temporais, correlações e anomalias;

- Desenvolver um conjunto expandido recursos preditores a partir dos dados brutos, incluindo variáveis de atraso, médias móveis, codificação cíclica e interações entre variáveis;
- Implementar e avaliar modelos de linha de base — Média Móvel Simples (MMS), Média Móvel Exponencial (MME), Regressão Linear Múltipla e SARIMA — sobre o conjunto de dados preparado;
- Implementar e avaliar modelos avançados — MLP, *Random Forest*, *XGBoost* e LSTM — com validação cruzada temporal e otimização de hiperparâmetros por busca em grade;
- Comparar os resultados de todos os modelos por meio das métricas MAE, RMSE, R^2 e MAPE, identificando o melhor algoritmo e os recursos mais determinantes para a previsão;
- Analisar a importância das variáveis para os modelos baseados em árvore, identificando os recursos que mais contribuem para a redução do erro de predição.

2. Coleta de Dados

A base de dados utilizada nesse estudo é a *Building Sites Power Consumption*, disponibilizada por Möbius (2021) na plataforma Kaggle. O objetivo da publicação é justamente incentivar o estudo de previsões de consumo energético em edifícios. Os dados estão organizados em tabelas relacionadas, com identificadores que permitem realizar junções entre as diferentes fontes de informação.

Conforme descrito em COELHO (2021b), "a base possui dados estruturados de energia de edifícios, medições de temperatura, distâncias entre o ponto de medição de temperatura do prédio, contagem de feriados e área construída". Essa estrutura multivariada possibilita a exploração de correlações entre o consumo energético e as condições climáticas, além da influência do calendário sobre o padrão de uso dos edifícios. A base de dados é composta por quatro arquivos principais, descritos na Tabela 1. A Figura 1 ilustra a distribuição de registros entre os 267 edifícios disponíveis, evidenciando a alta concentração

de medições em poucos prédios e a linha de corte adotada para seleção dos candidatos ao estudo.

Tabela 1 — Descrição dos conjuntos de dados da base Building Sites Power Consumption

Arquivo	Dimensões	Colunas principais	Descrição
plfec-train-data.csv	$6.559.830 \times 5$	obs_id, SiteId, Timestamp, ForecastId, Value	Medições de consumo energético (kWh) por edifício e instante de tempo
plfec-weather.csv	$3.957.035 \times 4$	Timestamp, Temperature, Distance, SiteId	Medições de temperatura (°C) com distância ao ponto de medição
plfec-holidays.csv	8.387×3	Date, Holiday, SiteId	Feriados locais por edifício
plfec-metadata.csv	267×11	SiteId, Surface, Sampling, BaseTemperature, flags de dias de folga	Metadados dos edifícios, incluindo área construída e padrão de funcionamento

Fonte: O autor.




Figura 1 — Registros de energia por prédio e histograma com limiar de 10.000 medições. Fonte: O autor.

O período global coberto pela base de dados de energia vai de junho de 2009 a dezembro de 2017, considerando todos os 267 edifícios disponíveis. A frequência de medição varia entre os edifícios, conforme indicado pelo campo *Sampling* da tabela de metadados disponibiliza na plataforma.

3. Processamento/Tratamento de Dados

O processamento dos dados foi realizado em linguagem de programação *Python*, com o uso das bibliotecas *pandas*, para manipulação de dados tabulares, e *matplotlib*, para visualização. Conforme afirma McKinney (2019), "a biblioteca *pandas* contém estruturas de dados e ferramentas para manipulação de dados, projetadas para agilizar e facilitar a limpeza e a análise de dados em *Python*".

3.1 Junção entre as bases de dados

A primeira etapa do processamento consistiu em isolar os registros do edifício de identificador 40 a partir da tabela de consumo energético global. Esse edifício, conforme abordado no trabalho anterior, está entre os que possuem mais dados de consumo de energia em sua série temporal. Em seguida, realizou-se a junção da tabela de energia com a tabela de temperatura por meio de uma operação *inner join* sobre o campo *Timestamp*, restando apenas os instantes com medição disponível nas duas fontes. Para tratar os casos de múltiplas medições de temperatura por instante, decorrentes de diferentes distâncias entre o ponto de coleta e o edifício, os registros foram ordenados pelo campo *Distance* e as linhas duplicadas para o mesmo instante foram descartadas, mantendo-se apenas a de menor distância, seguindo a abordagem do trabalho anterior.

Após a junção, foram adicionadas as colunas de marcação de feriado a partir da tabela *plfec-holidays.csv*, associadas ao identificador do edifício. O resultado dessa etapa foi um arquivo consolidado com 16.995 linhas e 12 colunas, correspondendo ao conjunto de dados integrado do edifício 40. A redução de 17.352 para 16.995 registros decorre da ausência de correspondência de temperatura em 357 instantes de medição de energia, representando uma cobertura de 97,9% da série original. Por fim, segundo os metadados disponibilizados, o edifício apresenta área construída de 393,36 m², temperatura de base de 18 °C e dias de folga nos fins de semana (sábado e domingo).

3.2 Identificação de valores ausentes e gaps temporais

A análise da distribuição dos intervalos entre as medições revelou que 17 registros apresentaram lacunas (gaps) de 193 horas, equivalentes a aproximadamente oito dias, enquanto o restante da base manteve intervalo consistente de uma hora entre as medições. Conforme abordado em COELHO (2021b), esses gaps não foram descartados da base de dados, uma vez que a separação empregada entre os conjuntos de treino e teste é temporal e cronológica, e a presença de lacunas faz parte das características reais da série.

Com relação a valores ausentes nos campos de energia e temperatura, não foram identificadas ocorrências após a junção por *inner join*. Dessa forma, todos os 16.995 registros resultantes da junção foram mantidos para a etapa seguinte de engenharia de recursos.

3.3 Identificação de outliers

A identificação de valores atípicos foi realizada por dois métodos. O primeiro utilizou o critério de amplitude interquartílica (IQR), definindo como outliers os valores abaixo de $Q1 - 1,5 \times IQR$ e acima de $Q3 + 1,5 \times IQR$. O segundo aplicou o *Z-score*, considerando como atípicos os registros com $|z| > 3$. Pelos critérios IQR e *Z-score*, foram identificados 116 outliers (0,7% da base) e zero registros com *Z-score* acima de três, respectivamente.

Diante da baixa proporção de valores atípicos e da possibilidade de que picos noturnos façam parte do comportamento legítimo do edifício, optou-se por manter os outliers na base de dados. A Figura 2 apresenta a análise de outliers realizada a partir do estudo descrito acima.




Figura 2 — Identificação de outliers SiteId = 40. Fonte: O autor.

3.4 Engenharia de recursos

A etapa de engenharia de recursos, ampliou o conjunto de variáveis preditoras de seis, previamente adotado em COELHO (2021b), para vinte variáveis. O objetivo foi capturar padrões de autocorrelação temporal, sazonalidade em múltiplas escalas e interações entre temperatura e hora do dia, que são componentes relevantes para a previsão de consumo energético, conforme apontado por Deb et al. (2017) em sua revisão sobre previsão de energia em edifícios.

A Tabela 2 descreve os vinte recursos gerados, indicando quais já estavam presentes na abordagem do TCC de graduação (COELHO, 2021b) e quais foram incorporados no presente estudo.

Tabela 2 — Descrição dos recursos preditores criados na etapa de engenharia de recursos

Recurso	Descrição	Origem
hr_sin, hr_cos	Codificação cíclica da hora do dia: sen e cos de $(2\pi \times (\text{hora} + \text{min}/60) / 24)$	COELHO (2021b)
energy_lag1	Consumo energético no instante anterior (t-1)	COELHO (2021b)
temp_lag1	Temperatura no instante anterior (t-1)	COELHO (2021b)
is_holiday	Indicador binário de feriado (0 ou 1)	COELHO (2021b)
Temperature	Temperatura atual no instante t	COELHO (2021b)
dow_sin, dow_cos	Codificação cíclica do dia da semana	Novo
month_sin, month_cos	Codificação cíclica do mês do ano	Novo
energy_lag2	Consumo energético em t-2	Novo
energy_lag24	Consumo energético em t-24 (mesmo horário do dia anterior)	Novo
temp_lag2	Temperatura em t-2	Novo
roll_mean_6h	Média móvel de 6 passos do consumo energético	Novo
roll_mean_24h	Média móvel de 24 passos do consumo energético	Novo
roll_std_24h	Desvio padrão móvel de 24 passos do consumo energético	Novo
delta_temp	Diferença de temperatura entre t e t-1	Novo
delta_energy	Diferença de consumo entre t e t-1	Novo
temp_x_hour	Interação multiplicativa entre temperatura e hora do dia	Novo
is_weekend	Indicador binário de fim de semana (0 ou 1)	Novo

Fonte: O autor.

A Figura 3 ilustra o resultado da codificação cíclica aplicada aos três ciclos temporais, mostrando as curvas seno e cosseno geradas para hora do dia, dia da semana e mês do ano.




Figura 3 — Codificação cíclica via seno e cosseno para hora do dia (TCC2), dia da semana (novo) e mês do ano (novo). Fonte: O autor.

A codificação cíclica da hora do dia, já presente em COELHO (2021b) com base na metodologia de Kaleko (2017), foi estendida para os demais ciclos temporais relevantes — dia da semana e mês do ano. Conforme afirmado naquele trabalho, "esse recurso matemático permite que o algoritmo consiga realizar as interpretações que para o ser humano são lógicas, mas que para a máquina não são apresentadas com clareza nos primeiros treinos". A inclusão do dia da semana em codificação cíclica tem como objetivo que o algoritmo perceba a continuidade entre sexta-feira e segunda-feira sem o artefato de uma diferença numérica artificial de 6 para 0. O trecho de código abaixo exemplifica como isso foi realizado:

```
def cyclical_encode(series, period):
    """Codifica uma variável cíclica em componentes seno e cosseno."""
    s = np.sin(2 * np.pi * series / period)
    c = np.cos(2 * np.pi * series / period)
    return s, c

# Hora do dia (período=24) — mesmo do TCC2, porém com minutos quando disponível
df['hour'] = df['Timestamp'].dt.hour
df['minute'] = df['Timestamp'].dt.minute
hour_float = df['hour'] + df['minute'] / 60.0
df['hr_sin'], df['hr_cos'] = cyclical_encode(hour_float, 24) # TCC2 original

# Dia da semana (período=7) — NOVO
df['dayofweek'] = df['Timestamp'].dt.dayofweek
df['dow_sin'], df['dow_cos'] = cyclical_encode(df['dayofweek'], 7)

# Mês do ano (período=12) — NOVO
df['month'] = df['Timestamp'].dt.month
df['month_sin'], df['month_cos'] = cyclical_encode(df['month'], 12)

print('Encoding cíclico aplicado:')
print(df[['Timestamp', 'hr_sin', 'hr_cos', 'dow_sin', 'dow_cos', 'month_sin', 'month_cos']
].head(5).to_string())
```

Após a geração dos recursos por operações de atraso (*lag*) e janelas móveis (*rolling*), as linhas com valores ausentes decorrentes dessas operações foram removidas por pelo método *dropna()*. Esse procedimento eliminou 363 registros (2,1% do total), resultando em uma base final de 16.632 linhas e 22 colunas (o índice de tempo, a variável alvo *Value* e os 20 recursos preditores), exportada para o arquivo um arquivo. A normalização dos dados não foi aplicada na exportação, sendo realizada de forma individual dentro do pipeline de cada modelo, a fim de evitar vazamento de informação entre os conjuntos de treino e teste.

A Figura 4 ilustra a aplicação das médias móveis de 6 e 24 horas sobre as duas primeiras semanas da série, evidenciando o efeito de suavização em diferentes escalas de tempo. Adicionalmente, a Figura 5 apresenta o ranking de correlação de todos os vinte recursos com a variável alvo, que orientou a interpretação da relevância relativa de cada preditor.




Figura 4 — Consumo energético original em comparação com as médias móveis de 6 horas e 24 horas. Fonte: O autor.




Figura 5 — Ranking de correlação de Pearson dos 20 recursos preditores com a variável alvo. Fonte: O autor.

4. Análise e Exploração dos Dados

Realizou-se uma análise exploratória de dados (EDA) nos dados integrados do edifício 40 para entender a distribuição do consumo de energia, a série temporal e as correlações com outras variáveis, antes de qualquer tentativa de modelagem. Essa etapa é fundamental, pois, conforme afirmam Rallapalli & Ghosh (2012), "os primeiros parâmetros extraídos são a média aritmética e a variância/desvio padrão, além do valor máximo e mínimo", que norteiam as escolhas metodológicas subsequentes.

A Figura 6 apresenta a série temporal completa do consumo energético do edifício 40, no período de julho de 2015 a novembro de 2017. Nela, é possível identificar os padrões de alta variabilidade, os gaps periódicos e a sazonalidade anual, com consumo mais elevado nos meses de inverno.




Figura 6 — Série temporal completa de consumo energético do edifício 40 (jul/2015 – nov/2017). Fonte: O autor.

O edifício de referência apresenta consumo médio de 5.476,04 kWh por hora, com desvio padrão de 3.950,01 kWh. A grande variação (72,1% em média) indica uma série temporal bastante diversa, com a qual é difícil prever uma estacionariedade ou baixa variância residual. O intervalo mediano entre as medições é de exatamente uma hora, e 75% dos intervalos são iguais a esse valor, confirmando a regularidade da série, com exceção dos gaps mencionados no tópico 3.2.

Em relação à temperatura, a série apresenta média de 12,55 °C e desvio padrão de 8,23 °C, com amplitude entre -8 °C e 38 °C. A presença de temperaturas negativas é consistente com a localização do edifício em região de clima temperado e justifica o padrão de consumo elevado no período noturno e nos meses de inverno.

Ainda sobre o perfil do edifício 40 e para corroborar com o tópico 3.4, elaborou-se o gráfico da Figura 7 com os perfis médios de consumo por hora do dia, por dia da semana e por mês do ano — que serviram de base para a decisão sobre quais recursos cíclicos incluir na etapa de engenharia de recursos.




Figura 7 — Perfil de consumo médio por hora do dia (esquerda), dia da semana (centro) e mês do ano (direita). Fonte: O autor.

O consumo é mais elevado nos horários noturnos, com picos na hora 23 (8.137 kWh médios) e na hora 0 (6.900 kWh), e vale mínimo nas horas 20 e 21 (em torno de 3.039 a 3.188

kWh). Esse padrão, atípico em relação a edifícios de escritório convencionais, nos quais o pico ocorre no horário comercial, podem ser justificados pelo uso de sistemas de aquecimento em resposta às temperaturas negativas noturnas, conforme discutido em COELHO (2021b). Ainda sobre a Figura 7, verifica-se uma queda expressiva no consumo nos fins de semana, que se mostra coerente com os metadados do edifício, que indicam sábado e domingo como dias de folga. Por fim, ainda existe uma sazonalidade no gráfico mensal, que pode ser justificado pela variação de temperatura anual com estações bem definidas.

Ainda sobre o tema de sazonalidade, realizou-se a decomposição da série temporal utilizando o método *Seasonal and Trend decomposition using Loess* (STL), com período de 24 horas e parâmetro *robust=True*, que reduz a influência de outliers na estimação das componentes. A Figura 8 apresenta as quatro componentes resultantes da decomposição. A decomposição revelou três componentes principais: tendência, sazonalidade diária e resíduos.




Figura 8 — Decomposição STL da série temporal do edifício 40: série original, tendência, sazonalidade (período = 24h) e resíduo. Fonte: O autor.

Conforme abordado na seção 2.3.1 de COELHO (2021a), ao se realizar uma previsão das próximas ocorrências de uma série temporal "é preciso aceitar a premissa de que os

valores passados possuem influência nos valores futuros". Assim, a decomposição STL serve como uma base qualitativa para a escolha dos recursos de atraso e médias móveis na etapa de engenharia de recursos.

5. Criação de Modelos de Machine Learning

A criação dos modelos seguiu a divisão cronológica de 75% da base para treinamento e 25% para teste, aplicada sobre registros do arquivo com a base consolidada. A divisão cronológica é fundamental em séries temporais para evitar o vazamento de informação futura para o conjunto de treino, problema que ocorre quando se adota divisão aleatória (PEDREGOSA et al., 2011).

As métricas utilizadas para avaliação dos modelos foram:

- MAE (Mean Absolute Error) — erro médio absoluto, em kWh;
- RMSE (Root Mean Squared Error) — raiz do erro quadrático médio, em kWh;
- R^2 — coeficiente de determinação, que varia entre $-\infty$ e 1;
- MAPE (Mean Absolute Percentage Error) — erro percentual médio absoluto, em %.

5.1 Modelos de referência

A primeira etapa na construção dos modelos de *Machine Learning* foi a definição de um modelo de referência. Os *foundation models* (modelos de base) têm como objetivo estabelecer um referencial mínimo de desempenho a partir de métodos de menor complexidade computacional. Conforme defendem Zhao & Magoulès (2012), os modelos puramente estatísticos possuem menor complexidade de implementação e boa precisão, sendo uma opção relevante para conjuntos de dados menores ou quando se busca maior interoperabilidade.

Foram implementados quatro modelos de linha de base: Média Móvel Simples (MMS), Média Móvel Exponencial (MME), Regressão Linear e SARIMA (*Seasonal AutoRegressive Integrated Moving Average*).

Média Móvel Simples (MMS), conforme Martins & Laugen (2005), calcula a previsão do período futuro como a média de n períodos anteriores. Foram avaliadas janelas de 6, 12 e 24 horas. O melhor resultado foi obtido com $R^2 = 0,468$, na janela de 12 horas.

Por sua vez, na Média Móvel Exponencial (MME) a previsão é calculada a partir da última previsão realizada adicionada ou subtraída de um coeficiente α que multiplica o dado real. Avaliou-se os coeficientes $\alpha \in \{0,1; 0,3; 0,5\}$. O melhor resultado, com $R^2 = 0,619$, foi obtido com o parâmetro $\alpha = 0,5$, evidenciando que um peso maior sobre os valores mais recentes se ajusta melhor ao comportamento do edifício.

A implementação do modelo de Regressão Linear Múltipla considerou os seguintes nove recursos de entrada: *Temperature*, *temp_lag1*, *energy_lag1*, *hr_sin*, *hr_cos*, *dow_sin*, *dow_cos*, *is_weekend* e *is_holiday*. O resultado no conjunto de teste foi $R^2 = 0,707$, o melhor entre os modelos de linha de base. Os coeficientes obtidos indicam que *is_weekend* ($-424,2$) e *is_holiday* ($-284,1$) são os regressores de maior magnitude, confirmando a forte influência do calendário sobre o consumo do edifício. O recurso *energy_lag1* apresentou coeficiente de $0,834$, evidenciando a autocorrelação da série.

Por fim, o método SARIMA (ARIMA Sazonal) foi ajustado automaticamente pela biblioteca *pmdarima* com parâmetro $m = 24$ (ciclo diário), resultando na ordem $(3, 0, 0)(1, 0, 0)_{24}$. Por limitações computacionais, o SARIMA foi treinado sobre os 336 registros finais do conjunto de treino (duas semanas) e avaliado sobre os 48 primeiros registros do conjunto de teste (dois dias), o que impede comparação direta com os demais modelos sobre a série completa. No subconjunto avaliado, o SARIMA obteve $R^2 = 0,360$.

5.2 Modelos avançados

Os modelos avançados foram implementados sobre o conjunto completo de vinte recursos, com pipeline de normalização integrado ao processo de treino. A validação cruzada empregada foi o *TimeSeriesSplit* com cinco partições, que respeita a ordem cronológica dos dados ao criar subconjuntos de treino e validação, evitando o problema de vazamento de informação futura identificado quando se usa o *k-fold* aleatório. A revisão desse trabalho busca justamente reavaliar a metodologia apresentada previamente.

Adicionalmente, foi implementada a reprodução da configuração do TCC de graduação (COELHO, 2021b), denominada "MLP TCC2 original", utilizando os seis recursos originais e a arquitetura de 43 neurônios em camada oculta com 1.500 iterações. Essa reprodução tem como objetivo avaliar o impacto isolado da expansão dos recursos sobre o desempenho do mesmo algoritmo, mantendo os demais parâmetros constantes.

5.2.1 Reprodução do experimento prévio

A Tabela 3 apresenta a correspondência parâmetro a parâmetro entre as duas implementações, extraída diretamente do código-fonte do trabalho anterior (TCC graduação) e do notebook de modelos avançados desse projeto.

Tabela 3 — Confronto de parâmetros entre a implementação original do TCC2 (COELHO, 2021b) e a reprodução no presente estudo

Parâmetro	TCC2 — CEFET-MG (2021b)	Reprodução — PUC (2026)	Idêntico?
Biblioteca	sklearn.neural_network.MLPRegressor	sklearn.neural_network.MLPRegressor	Sim
Camada oculta	43 neurônios, 1 camada	hidden_layer_sizes=(43,)	Sim
Função de ativação	Tangente hiperbólica	activation='tanh'	Sim
Otimizador	Adam	solver='adam'	Sim
Iterações máximas	1.500	max_iter=1500	Sim
Normalização	MinMaxScaler([-1, 1]) via Pipeline	MinMaxScaler(feature_range=(-1, 1)) via Pipeline	Sim
Recursos de entrada	Temperatura atual, temperatura anterior, energia anterior, hora seno, hora cosseno, marcação de feriado	['Temperature', 'temp_lag1', 'energy_lag1', 'hr_sin', 'hr_cos', 'is_holiday']	Sim
Quantidade de recursos	6	6	Sim
Proporção treino/teste	75% / 25%	split_idx = int(len(df) * 0.75)	Sim
Codificação cíclica da hora	sen e cos de $(\text{hora} + \text{min}/60) \times 2\pi/24$	Idêntica, conforme Kaleko (2017)	Sim
Método de validação cruzada	k-fold aleatório, 10 partições	TimeSeriesSplit(n_splits=5)	Não - diferença intencional Adicionada para reprodutibilidade
Semente de aleatoriedade	Não especificada	random_state=42	

Fonte: O autor.

É importante citar que foi acrescentado o parâmetro *random_state=42* para garantir a reprodutibilidade determinística dos resultados, uma vez que o TCC2 não especificou semente

de aleatoriedade — o que torna seus resultados sujeitos à variação entre execuções, mas não altera os parâmetros estruturais do modelo. Diante do exposto, qualquer diferença de desempenho será atribuída exclusivamente à mudança na estratégia de validação cruzada e, nos demais experimentos do presente estudo.

Seguindo para a etapa prática, a reprodução da configuração de COELHO (2021b), agora avaliada com *TimeSeriesSplit*, revelou a instabilidade do modelo: os R^2 por partição foram $[-1,488; -1,779; -0,230; -0,696; -0,837]$, com média de $-1,006$ e desvio padrão de $0,558$. No conjunto de teste, o modelo obteve $R^2 = -0,108$, $RMSE = 2.916,40$ kWh e $MAPE = 75,6\%$. Esse resultado será melhor interpretado no tópico 6 desse trabalho.

5.2.2 MLP com recursos expandidos

O MLP com os vinte recursos foi otimizado por busca em grade (*GridSearchCV*) com *TimeSeriesSplit* ($n_splits=5$). A grade explorou combinações de tamanho de camada oculta — (43,), (50,), (100,) e (50, 25) — e número máximo de iterações — 1.500 e 3.000. O trecho de código abaixo apresenta a implementação dessa etapa:

```
# — MLP com features expandidas e GridSearchCV —————
pipe_mlp_new = Pipeline([
    ('scaler', MinMaxScaler(feature_range=(-1, 1))),
    ('mlp', MLPRegressor(activation='tanh', solver='adam', random_state=42))
])

param_grid_mlp = {
    'mlp__hidden_layer_sizes': [(43,), (50,), (100,), (50, 25)],
    'mlp__max_iter': [1500, 3000],
}

gs_mlp = GridSearchCV(
    pipe_mlp_new, param_grid_mlp,
    cv=tss, scoring='r2', n_jobs=1, verbose=0
)
gs_mlp.fit(X_train_f, y_train)

print(f'Melhores parâmetros MLP: {gs_mlp.best_params_}')
print(f'Melhor R² (CV) MLP      : {gs_mlp.best_score_:.5f}')

y_pred_mlp_new = gs_mlp.predict(X_test_f)
m = compute_metrics(y_test, y_pred_mlp_new, 'MLP (features expandidas)')
all_results.append(m)
```

```
print(f"Teste - MAE={m['MAE']:.4f} RMSE={m['RMSE']:.4f} R²={m['R²']:.5f}")
```

O melhor resultado de validação cruzada ($R^2 = 0,574$) foi obtido com 100 neurônios e 3.000 iterações. No conjunto de teste, o modelo expandido alcançou $R^2 = 0,99996$, RMSE = 17,49 kWh, MAE = 3,36 kWh e MAPE = 0,099%.

5.2.3 Random Forest

O *Random Forest* é um método aprendizado que constrói múltiplas árvores de decisão durante o treinamento e combina suas previsões pela média. Foram avaliadas combinações de número de estimadores (100 e 200), profundidade máxima (sem limite, 10 e 20) e critério de divisão mínima (2 e 5 amostras). Por sua vez, o trecho de código abaixo apresenta como a etapa foi implementada utilizando a linguagem *Python*.

```
pipe_rf = Pipeline([
    ('scaler', MinMaxScaler(feature_range=(-1, 1))),
    ('rf', RandomForestRegressor(random_state=42, n_jobs=-1))
])

param_grid_rf = {
    'rf__n_estimators': [100, 200],
    'rf__max_depth': [None, 10, 20],
    'rf__min_samples_split': [2, 5],
}

gs_rf = GridSearchCV(
    pipe_rf, param_grid_rf,
    cv=tss, scoring='r2', n_jobs=1, verbose=0
)

gs_rf.fit(X_train_f, y_train)

print(f'Melhores parâmetros RF: {gs_rf.best_params_}')
print(f'Melhor R² (CV) RF : {gs_rf.best_score_:.5f}')

y_pred_rf = gs_rf.predict(X_test_f)
m = compute_metrics(y_test, y_pred_rf, 'Random Forest')
all_results.append(m)
print(f"Teste - MAE={m['MAE']:.4f} RMSE={m['RMSE']:.4f} R²={m['R²']:.5f}")
```

No conjunto de teste, o melhor modelo em questão obteve $R^2 = 0,99928$, $RMSE = 74,57$ kWh, $MAE = 37,47$ kWh e $MAPE = 0,988\%$. Isso ocorreu para com o parâmetro de 200 estimadores, profundidade máxima de 20 e critério de 2 amostras.

5.2.4 XGBoost

O *XGBoost* (*eXtreme Gradient Boosting*) é um algoritmo baseado em árvore de decisão, amplamente utilizado em competições de ciência de dados pela combinação de desempenho elevado e velocidade de processamento. A grade explorou combinações de número de estimadores (100 e 300), profundidade máxima (4 e 6), taxa de aprendizado (0,05 e 0,1) e proporção de subamostras (0,8 e 1,0). A melhor configuração — R^2 de validação de 0,989 — foi: 300 estimadores, profundidade 4, taxa de aprendizado 0,05 e subamostra completa.

No conjunto de teste, o melhor modelo obteve $R^2 = 0.99786$, $RMSE = 128.16$ kWh, $MAE = 95.83$ kWh e $MAPE = 2,606\%$.

5.2.5 LSTM

A *Long Short-Term Memory* (LSTM) é uma arquitetura de rede neural recorrente especialmente projetada para aprender padrões em sequências temporais (WEI et al., 2017). A implementação utilizou o framework *TensorFlow* 2.21.0, com arquitetura composta por uma camada LSTM de 64 unidades, seguida por uma camada de *Dropout* de 20% para regularização, uma camada densa de 32 neurônios com ativação *ReLU* e uma camada de saída com um neurônio. O total de parâmetros treináveis foi de 23.873.

O treinamento foi realizado com o otimizador *adam* (padrão), função de perda MSE e métrica de acompanhamento MAE, por até 100 épocas com *batch size* de 128 e reserva de 10% do conjunto de treino para validação interna. O mecanismo de parada antecipada com limite de 10 épocas e restauração dos melhores pesos interrompeu o treinamento na 40ª época. A Figura 9 apresenta a curva de aprendizado da LSTM, evidenciando a rápida convergência nas primeiras cinco épocas e a estabilização a partir da décima.




Figura 9 – Curva de aprendizagem do modelo LST. Fonte: O autor.

6. Interpretação dos Resultados

No que se refere especificamente aos modelos de referência, evidencia-se que métodos estatísticos clássicos, embora adequados como base inicial, permanecem distantes da acurácia exigida para aplicações operacionais de monitoramento de consumo. A distância entre o melhor modelo de referência, Regressão Linear Múltipla, e o melhor modelo avançado, MLP com recursos expandidos, corresponde a uma redução de erro absoluto de 99,7%, o que demonstra que a incorporação de recursos adicionais e de algoritmos capazes de modelar relações não lineares produz ganhos que não podem ser alcançados pela simples expansão de variáveis dentro de um modelo linear.

Ainda assim, os modelos de linha de base cumprem a função para a qual foram concebidos: estabelecer que os algoritmos avançados não apenas apresentam métricas elevadas em termos absolutos, mas efetivamente superam alternativas simples e interpretáveis. Nesse sentido, qualquer modelo proposto para implantação em sistemas de gestão energética deve, no mínimo, superar o $R^2 = 0,707$ da Regressão Linear, patamar que, no presente estudo, foi cumprido pelos outros algoritmos avançados.

Seguindo para os modelos avançados, o primeiro ponto que se destaca nos resultados desse trabalho está relacionada com a performance do modelo de MLP com a troca do método de validação cruzada. Esse resultado, negativo em todas as partições da validação, indica que o modelo, com apenas seis recursos e avaliado em sequência cronológica, **não foi capaz de generalizar o comportamento da série para períodos futuros.**

Portanto, os resultados do presente estudo contrastam fortemente com o R^2 de 0,868 obtido em COELHO (2021b) com o mesmo algoritmo. A diferença se explica pelo método de validação: enquanto o trabalho anterior utilizou particionamento aleatório (*k-fold* com divisão randômica), o presente estudo aplica divisão estritamente cronológica. Dessa forma, o modelo anterior pode ter aprendido padrões futuros durante o treino, configurando um caso de **sobreajuste induzido** pela divisão não temporal dos dados.

Seguindo nas análises, o modelo MLP com recursos expandidos representa um ganho de significativo em relação à configuração original do TCC de graduação, evidenciando que a qualidade e a quantidade dos recursos de entrada são determinantes para a capacidade preditiva do modelo, sobrepondo-se à escolha da arquitetura da rede.

Os demais modelos avançados, Random Foreste, XGBoost e LSTM foram também satisfatórios nas previsões de 48 horas. Esse grupo de modelos disponibilizou resultados superiores à 99% de R^2 , o que indica que são capazes de explicar praticamente toda a variância dos dados. No entanto, avaliando-se outras métricas, como é o caso do MAPE, o MLP apresentou melhor desempenho. Isso significa que os demais modelos apesar de capturar bem a tendência geral dos dados, comentem erros percentuais mais relevantes que a rede neural, mas ainda são considerados bons resultados.

A Figura 10 apresenta um consolidado dos gráficos de dispersão entre o valor real e o valor previsto pelos modelos. É perceptível que o modelo do trabalho antigo, ajustado na validação cruzada considerando a ordem cronológica dos eventos, falha em se modelar a curva de consumo. Todavia, demais modelos apresentam resultados coerentes com o esperado, se ajustando a uma linha reta que cruza a origem do plano.




Figura 10 – Painel de dispersão dos modelos avançados (Real x Previsto). Fonte: O autor.

Adicionalmente, a Tabela 4 consolida os resultados de todos os modelos e, embora o MLP com recursos expandidos apresente o menor erro absoluto, a diferença de R^2 em relação ao *Random Forest* é de apenas 0,00068 pontos percentuais, margem que, na prática, se dilui diante da variabilidade natural dos dados. Do ponto de vista operacional, o *Random Forest* reúne vantagens que o tornam preferível para implantação: convergência garantida, ausência de hiperparâmetros críticos de otimização iterativa, interpretabilidade nativa por importância de variáveis e compatibilidade com pipelines de retreino periódico. Portanto, constata-se que o modelo *Random Forest* ocupa uma posição de equilíbrio entre os modelos.

Tabela 4 — Resumo e ranqueamento entre os modelos avaliados no conjunto de teste

Rank	Modelo	MAE (kWh)	RMSE (kWh)	R^2	MAPE (%)
1	MLP (recursos expandidos)	3,36	17,49	0,99996	0,099
2	Random Forest	37,47	74,57	0,99928	0,988
3	XGBoost	95,83	128,16	0,99786	2,606
4	LSTM	104,26	143,16	0,99733	3,715
5	Regressão Linear	1.083,81	1.499,36	0,70716	27,487
6	MME ($\alpha = 0,5$)	1.197,67	1.709,30	0,61941	29,263
7	MME ($\alpha = 0,3$)	1.296,05	1.802,95	0,57656	33,667

8	MME ($\alpha = 0,1$)	1.519,69	1.996,99	0,48051	45,349
9	MMS ($w = 12$)	1.492,18	2.020,43	0,46825	41,823
10	MMS ($w = 6$)	1.477,48	2.026,98	0,46479	38,345
11	MMS ($w = 24$)	1.639,58	2.150,14	0,39778	50,72
12	SARIMA (2 dias)*	1.449,66	1.761,82	0,36011	29,911
13	MLP (TCC2 original)	2.435,50	2.916,40	-0,10795	75,603

Fonte: O autor.

Finalizando a apresentação dos resultados, a Figura 11 mostra a importância de cada variável de entrega para os modelos *Random Forest* e *XGBoost*. Os recursos de maior poder preditivo, conforme revelado pelas análises de importância do *Random Forest* e do *XGBoost*, são *energy_lag1* e *delta_energy*, que capturam respectivamente o nível de consumo imediatamente anterior e a variação recente. A *roll_mean_6h* também contribui significativamente, incorporando a tendência de curto prazo da série. Esses três recursos concentram mais de 99% da importância total nos dois modelos baseados em árvore, o que indica uma alta autocorrelação da série. Interessantemente, as variáveis *is_weekend* e *is_holiday* apresentaram importância nula ou próxima de zero em ambos os modelos, sugerindo que o efeito do calendário já é capturado pelos recursos de atraso e médias móveis, que refletem indiretamente a redução de consumo nos períodos de folga.




Figura 11 – Importância de recurso de entrada para modelos *Random Forest* e *XGBoost*. Fonte: O autor.

7. Apresentação dos Resultados

A apresentação dos resultados será guiada pelo Canvas de Dorard (2015), uma estrutura metodológica para projetos de aprendizado de máquina que organiza as diferentes etapas do processo analítico, desde a definição do problema até a avaliação dos resultados obtidos. Com isso em mente, os achados deste estudo serão apresentados de acordo com os componentes propostos pela estrutura, a fim de descrever sistematicamente as decisões tomadas, os modelos desenvolvidos e as métricas utilizadas, além de facilitar a interpretação e a reprodutibilidade da pesquisa.

7.1 Problema Proposto

O ponto de partida desse estudo foi a identificação de uma lacuna metodológica nos trabalhos anteriores do autor (COELHO, 2021a; COELHO, 2021b). Verificou-se que a abordagem original, rede neural MLP com seis recursos de entrada e validação cruzada *k-fold* com particionamento aleatório, alcançou R^2 de 0,868 no conjunto de teste, resultado que, conforme demonstrado nesse trabalho, foi inflacionado pelo vazamento de informação futura para o conjunto de treino. Ao substituir o método de validação aleatório pela validação temporal com *TimeSeriesSplit*, o mesmo modelo, com os mesmos parâmetros e os mesmos dados, obteve R^2 médio de $-0,108$, evidenciando que o resultado anterior não era generalizável para períodos futuros.

Nesse sentido, o problema central que esse estudo se propôs a responder é: em que medida a expansão do conjunto de recursos preditores e a adoção de múltiplos algoritmos de aprendizado de máquina melhoram a capacidade de previsão do consumo energético de um edifício, em relação à abordagem anterior? A resposta, conforme demonstram os resultados, é clara: a engenharia de recursos expandida é o fator determinante para o desempenho preditivo, sobrepondo-se à escolha do algoritmo e à arquitetura da rede.

7.2 Previsões Realizadas

O objeto de previsão desse estudo é o consumo energético horário de um edifício, medido em quilowatt-hora (kWh), no horizonte de uma hora à frente, o chamado problema de previsão de curto prazo de um passo à frente (*one-step-ahead forecasting*). Essa formulação é relevante do ponto de vista aplicado, pois permite que gestores de edifícios antecipem o comportamento do consumo com granularidade horária, identificando desvios em relação ao padrão esperado e orientando decisões de manutenção e controle de demanda.

7.3 Aquisição de Dados

Os dados utilizados nesse estudo foram obtidos da base pública *Building Sites Power Consumption*, disponibilizada por Möbius (2021) na plataforma *Kaggle*. A base compreende registros de consumo energético e temperatura de 267 edifícios, estruturados em quatro arquivos relacionais. O edifício de referência, identificado pelo código *SiteId* = 40, foi selecionado por critérios objetivos: apresenta 17.352 registros brutos de consumo, cobertura de 97,9% da informação de temperatura no mesmo instante das medições de energia e perfil de consumo com padrões sazonais bem definidos.

7.4 Preparação dos Dados

A preparação dos dados constituiu uma das etapas mais decisivas do estudo. A partir dos registros brutos, foi construído um conjunto de vinte variáveis preditoras que capturam diferentes aspectos da dinâmica do consumo: autocorrelação de curto prazo, tendência recente, sazonalidade múltipla e influências climáticas. As principais contribuições dessa etapa foram a criação de variáveis de atraso de ordens 1, 2 e 24 (sendo *energy_lag1* a variável de maior correlação com o alvo) médias móveis de janelas de 6 e 24 horas e a codificação cíclica das variáveis temporais por meio de funções seno e cosseno, conforme metodologia proposta por Kaleko (2017).

A análise exploratória revelou padrões estruturais relevantes: sazonalidade intradiária com pico de consumo entre 7h e 18h, queda pronunciada aos fins de semana e feriados, e ausência de tendência crescente ou decrescente ao longo do período. Torna-se, portanto,

justificável afirmar que a qualidade do conjunto de recursos preditores é o principal determinante do desempenho dos modelos de previsão nesse contexto.

7.5 Modelos Implementados

Foram implementados dois grupos de modelos. O primeiro, denominado modelos de referência, compreende métodos de menor complexidade computacional empregados como referência mínima de desempenho: Média Móvel Simples (MMS), Média Móvel Exponencial (MME), Regressão Linear Múltipla e SARIMA. O melhor resultado desse grupo foi obtido pela Regressão Linear, com $R^2 = 0,707$, que se beneficiou da inclusão de variáveis relacionadas ao calendário e de atraso entre seus nove recursos de entrada. Os métodos univariados (MMS e MME) ficaram restritos ao intervalo $R^2 \in [0,398; 0,619]$, evidenciando que o uso exclusivo do histórico da série, sem variáveis exógenas, é insuficiente para capturar a variabilidade do consumo.

O segundo grupo, denominado modelos avançados, foi implementado sobre o conjunto completo de vinte recursos preditores, com normalização integrada ao processo de treino e validação cruzada temporal de cinco partições. Foram avaliados quatro algoritmos: MLP, *Random Forest*, *XGBoost* e LSTM. Adicionalmente, foi reproduzida a configuração original de COELHO (2021b), com os seis recursos originais e avaliação por *TimeSeriesSplit*, como experimento de controle para isolar o efeito da engenharia de recursos. A otimização de hiperparâmetros foi conduzida por busca em grade para os modelos baseados em árvore e para o MLP; a LSTM foi treinada com arquitetura fixa e mecanismo de parada antecipada.

7.6 Avaliação dos Modelos

Os resultados obtidos permitem responder, de forma objetiva, ao problema proposto. O MLP com recursos expandidos alcançou $R^2 = 0,99996$, RMSE = 17,49 kWh e MAPE = 0,099%, sendo esse o melhor desempenho absoluto entre todos os modelos avaliados, representando um ganho relativo de 15,2% em R^2 em relação à configuração original do TCC de graduação, que evidência desse trabalho, apresentou sobreajuste induzido. O Random

Forest e o XGBoost também apresentaram R^2 superior a 99%, com MAPE abaixo de 3%, confirmando a viabilidade de múltiplos algoritmos para essa tarefa. A LSTM obteve $R^2 = 0,997$, desempenho compatível com os demais modelos avançados, embora ligeiramente inferior — resultado que pode ser atribuído à arquitetura de camada única e ao horizonte de treinamento interrompido pela parada antecipada na 40ª época.

Do ponto de vista operacional, o Random Forest destaca-se como alternativa preferível ao MLP para implantação em sistemas de gestão energética: apresenta R^2 de 0,999, convergência garantida, ausência de hiperparâmetros críticos de otimização iterativa e interpretabilidade nativa por meio da importância de variáveis. Ainda assim, o MLP expandido permanece como o modelo de menor erro absoluto e pode ser adotado em cenários onde a precisão de previsão é prioritária em relação à interpretabilidade.

A partir desses achados, identificam-se perspectivas relevantes para pesquisas futuras: A extensão da metodologia para horizontes de previsão de múltiplos passos, não se limitando apenas à próxima ocorrência da série; A validação se o modelo desse estudo se aplica para edifícios com histórico reduzido; A aplicação direta dos modelos aqui desenvolvidos para o auxílio à gestão de faturas de energia em prédios públicos.

8. Links

Link para o vídeo: [youtube.com/...](https://www.youtube.com/watch?v=...)

Obs: Os códigos dos notebooks *Python* se encontram no APÊNDICE.

REFERÊNCIAS

- ABESCO, Associação Brasileira das Empresas de Serviços de Conservação de Energia. **O que é Eficiência Energética? (EE)**. Disponível em: <<https://www.abesco.com.br/pt/o-que-e-eficiencia-energetica-ee>>. Acesso em: 27 dez. 2020.
- AMASYALI, K.; EL-GOHARY, N. M. A review of data-driven building energy consumption prediction studies. **Renewable and Sustainable Energy Reviews**, p. 1192–1205, 2017.
- BUSSAB, W. D.; MORETTIN, P. A. **Estatística Básica**. São Paulo: Editora Saraiva, 2010.
- COELHO, Evandro Ribeiro Gomes. **Previsão de Curto Prazo do Consumo Energético de Prédios Públicos em Minas Gerais**. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Elétrica). Centro Federal de Educação Tecnológica de Minas Gerais, Belo Horizonte, 2021a.
- COELHO, Evandro Ribeiro Gomes. **Previsão do Consumo Energético de Prédios Públicos por Rede Neural Artificial MLP**. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Elétrica). Centro Federal de Educação Tecnológica de Minas Gerais, Belo Horizonte, 2021b.
- D'ALBUQUERQUE, M. A.; SILVA, R. M.; GOMES, M. B. Eficiência energética em uma edificação pública: uma análise das possibilidades. **Sistemas & Gestão**, p. 462-470, 2017.
- DEB, C. et al. A review on time series forecasting techniques for building energy consumption. **Renewable and Sustainable Energy Reviews**, p. 9-12, 2017.
- DORARD, Louis. **Machine Learning Canvas**. OWNML, 2015. Disponível em: <<https://www.ownml.co/machine-learning-canvas>>. Acesso em: 7 jun. 2026.
- GONÇALVES, A. C. **Eficientização Energética em Prédios Públicos: um desafio aos gestores municipais frente aos requisitos de governança e sustentabilidade**. Dissertação de Mestrado. São Paulo, p. 1-25, 2012.
- HYNDMAN, J. R.; ATHANASOPOULOS, G. **Forecasting: Principles and Practice**. Melbourne: OTexts, 2018.
- KALEKO, D. Feature Engineering — Handling Cyclical Features. Disponível em: <<https://blog.davidkaleko.com/feature-engineering-cyclical-features.html>>. Acesso em: 13 jun. 2021.
- MARTINS, P.; LAUGENI, F. P. **Administração da Produção**. São Paulo: Editora Saraiva, 2005.
- McKINNEY, W. **Python Para Análise de Dados**. Tratamento de dados com Pandas, Numpy e iPython. 1. ed. São Paulo: Novatec Editora, 2019.

MÖBIUS. **Building Sites Power Consumption**. Forecast energy consumption in different time steps and granularities. Disponível em: <<https://www.kaggle.com/arashnic/building-sites-power-consumption-dataset>>. Acesso em: 12 jun. 2021.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **JMLR**, v. 12, p. 2825-2830, 2011.

PROCEL, Programa Nacional de Conservação de Energia Elétrica. **Edificações**. Disponível em: <<https://www.procelinfo.com.br>>. Acesso em: 15 out. 2020.

RALLAPALLI, S. R.; GHOSH, S. Forecasting monthly peak demand of electricity in India — a critique. **Energy Policy**, p. 516–520, 2012.

SILVA, I. N. et al. **Artificial Neural Networks — A Practical Course**. 1. ed. São Carlos: Springer, 2017.

TABRIZCHI, H.; JAVIDI, M. M.; AMIRZADEH, V. Estimates of residential building energy consumption using. **Evolving Systems**, 2019.

WEI, Y. et al. A review of data-driven approaches for prediction and classification of building energy consumption. **Renewable and Sustainable Energy Reviews**, p. 1-21, 2017.

ZHAO, H.; MAGOULÈS, F. A review on the prediction of building energy consumption. **Renewable and Sustainable Energy Reviews**, p. 1-7, 2012.

ZMEUREANU, J.; RUNGE, R. Forecasting energy use in buildings using artificial neural networks: a review. **Energies**, p. 5-8, 2019.

APÊNDICE

Notebooks anexados ao documento:

1. 01_eda.ipynb
2. 02_feature_engineering.ipynb
3. 03_baseline_models.ipynb
4. 04_advanced_models.ipynb
5. 05_results_comparison.ipynb